Analyse Statistique des Jeux Olympiques (1896–2016)

Travail réalisé par :Nada Rekik-Yasmine Frikha

Dataset : Olympic Athletes Events — Kaggle

Projet de Statistiques Descriptives et Inférentielles

ESCT / ISAMM — 2e LBDAD

Année universitaire 2025–2026

Partie I — Présentation du Dataset

1. Description Générale

Dans le cadre de ce projet, nous avons choisi le dataset Olympic Athletes Events, disponible sur la plateforme Kaggle. Ce dataset recense l'ensemble des participations aux Jeux Olympiques modernes, de la première édition d'Athènes en 1896 jusqu'aux Jeux de Rio en 2016.

2. Dimensions du Dataset

271 116 observations × 15 variables

```
> dim(data)
[1] 271116     15
```

Figure 1 : Résultat de dim(data) — 271 116 observations et 15 variables

```
> head(data)
  ID                      Name Sex Age Height Weight
1  1                 A Dijiang   M  24    180     80
2  2                  A Lamusi   M  23    170     60
3  3       Gunnar Nielsen Aaby   M  24     NA     NA
4  4      Edgar Lindenau Aabye   M  34     NA     NA
5  5 Christine Jacoba Aaftink   F  21    185     82
6  5 Christine Jacoba Aaftink   F  21    185     82
              Team NOC        Games Year Season
1            China CHN 1992 Summer 1992 Summer
2            China CHN 2012 Summer 2012 Summer
3          Denmark DEN 1920 Summer 1920 Summer
4 Denmark/Sweden DEN 1900 Summer 1900 Summer
5      Netherlands NED 1988 Winter 1988 Winter
6      Netherlands NED 1988 Winter 1988 Winter
       City          Sport
1 Barcelona     Basketball
2    London          Judo
3 Antwerpen      Football
4     Paris     Tug-Of-War
5   Calgary Speed Skating
6   Calgary Speed Skating
                                Event Medal
1         Basketball Men's Basketball  <NA>
2       Judo Men's Extra-Lightweight  <NA>
3            Football Men's Football  <NA>
4         Tug-Of-War Men's Tug-Of-War  Gold
5   Speed Skating Women's 500 metres  <NA>
6 Speed Skating Women's 1,000 metres  <NA>
```

Figure 2 : Aperçu des premières lignes avec head(data)

3. Description des Variables

Les variables sont de types différents. Le dataset contient des variables quantitatives comme l'âge, la taille et le poids, ainsi que des variables qualitatives comme le sexe, le sport et le type de médaille.

```
> str(data)
'data.frame':   271116 obs. of  15 variables:
 $ ID    : int  1 2 3 4 5 5 5 5 5 5 ...
 $ Name  : Factor w/ 134732 levels "  Gabrielle Marie \"Gabby\" Adcock (White-)",..: 8 9 44318 29412 21470 21470 21470 21470 21470 21470 ...
 $ Sex   : Factor w/ 2 levels "F","M": 2 2 2 2 1 1 1 1 1 1 ...
 $ Age   : int  24 23 24 34 21 21 25 25 27 27 ...
 $ Height: int  180 170 NA NA 185 185 185 185 185 185 ...
 $ Weight: num  80 60 NA NA 82 82 82 82 82 82 ...
 $ Team  : Factor w/ 1184 levels "30. Februar",..: 199 199 273 278 705 705 705 705 705 705 ...
 $ NOC   : Factor w/ 230 levels "AFG","AHO","ALB",..: 42 42 56 56 146 146 146 146 146 146 ...
 $ Games : Factor w/ 51 levels "1896 Summer",..: 38 49 7 2 37 37 39 39 40 40 ...
 $ Year  : int  1992 2012 1920 1900 1988 1988 1992 1992 1994 1994 ...
 $ Season: Factor w/ 2 levels "Summer","Winter": 1 1 1 1 2 2 2 2 2 2 ...
 $ City  : Factor w/ 42 levels "Albertville",..: 6 18 3 27 9 9 1 1 17 17 ...
 $ Sport : Factor w/ 66 levels "Aeronautics",..: 9 33 25 62 54 54 54 54 54 54 ...
 $ Event : Factor w/ 765 levels "Aeronautics Mixed Aeronautics",..: 160 398 349 710 623 619 623 619 623 619 ...
 $ Medal : Factor w/ 3 levels "Bronze","Gold",..: NA NA NA 2 NA NA NA NA NA NA ...
>
```

Figure 3 : Structure détaillée du dataset avec str(data)

Variable	Type	Description
ID	Quantitative discrète	Identifiant unique de l'athlète
Name	Qualitative nominale	Nom complet de l'athlète
Sex	Qualitative nominale	Sexe : M (Homme) ou F (Femme)
Age	Quantitative continue	Âge de l'athlète en années
Height	Quantitative continue	Taille de l'athlète en centimètres
Weight	Quantitative continue	Poids de l'athlète en kilogrammes
Team	Qualitative nominale	Nom de l'équipe ou du pays
NOC	Qualitative nominale	Code pays sur 3 lettres (ex : FRA, USA)
Games	Qualitative nominale	Édition des JO (ex : 2012 Summer)
Year	Quantitative discrète	Année des Jeux Olympiques
Season	Qualitative nominale	Saison : Summer (Été) ou Winter (Hiver)
City	Qualitative nominale	Ville hôte des Jeux
Sport	Qualitative nominale	Discipline sportive (ex : Athletics)
Event	Qualitative nominale	Épreuve précise (ex : 100m hommes)
Medal	Qualitative ordinale	Médaille : Gold, Silver, Bronze ou NA

4. Pourquoi ce Dataset ?

Nous avons choisi ce dataset pour trois raisons principales :

- **Richesse et variété :** il contient à la fois des variables quantitatives (Age, Height, Weight) et des variables qualitatives (Sex, Sport, Medal), ce qui permet d'appliquer toutes les méthodes statistiques vues en cours : analyse univariée, bivariée et multivariée.
- **Sujet universel et concret :** les Jeux Olympiques sont connus de tous. Les résultats obtenus sont faciles à interpréter, ce qui rend l'analyse plus intéressante et plus parlante.
- **Qualité des données :** les variables sont bien définies et les valeurs manquantes sont justifiées. Par exemple, les 85% de NA dans la colonne Medal s'expliquent simplement par le fait que la grande majorité des athlètes ne remportent pas de médaille.

Partie II — Analyse Univariée

La commande summary(data) dans R nous permet d'obtenir un aperçu complet de la distribution de chaque variable du dataset.

```
> summary(data)
       ID                                  Name        Sex             Age              Height           Weight                Team
 Min.   :     1   Robert Tait McKenzie     :    58   F: 74522   Min.   :10.00   Min.   :127.0   Min.   : 25.0   United States: 17847
 1st Qu.: 34643   Heikki Ilmari Savolainen:    39   M:196594   1st Qu.:21.00   1st Qu.:168.0   1st Qu.: 60.0   France       : 11988
 Median : 68205   Joseph "Josy" Stoffel    :    38              Median :24.00   Median :175.0   Median : 70.0   Great Britain: 11404
 Mean   : 68249   Ioannis Theofilakis      :    36              Mean   :25.56   Mean   :175.3   Mean   : 70.7   Italy        : 10260
 3rd Qu.:102097   Takashi Ono              :    33              3rd Qu.:28.00   3rd Qu.:183.0   3rd Qu.: 79.0   Germany      :  9326
 Max.   :135571   Alexandros Theofilakis   :    32              Max.   :97.00   Max.   :226.0   Max.   :214.0   Canada       :  9279
                  (Other)                  :270880              NA's   :9474    NA's   :60171   NA's   :62875   (Other)      :201012
      NOC             Games             Year          Season             City           Sport
 USA    : 18853   2000 Summer: 13821   Min.   :1896   Summer:222552   London       : 22426   Athletics : 38624
 FRA    : 12758   1996 Summer: 13780   1st Qu.:1960   Winter: 48564   Athina       : 15556   Gymnastics: 26707
 GBR    : 12256   2016 Summer: 13688   Median :1988                   Sydney       : 13821   Swimming  : 23195
 ITA    : 10715   2008 Summer: 13602   Mean   :1978                   Atlanta      : 13780   Shooting  : 11448
 GER    :  9830   2004 Summer: 13443   3rd Qu.:2002                   Rio de Janeiro: 13688   Cycling   : 10859
 CAN    :  9733   1992 Summer: 12977   Max.   :2016                   Beijing      : 13602   Fencing   : 10735
 (Other):196971   (Other)    :189805                                  (Other)      :178243   (Other)   :149548
                                 Event          Medal
 Football Men's Football               :  5733   Bronze: 13295
 Ice Hockey Men's Ice Hockey           :  4762   Gold  : 13372
 Hockey Men's Hockey                   :  3958   Silver: 13116
 Water Polo Men's Water Polo           :  3358   NA's  :231333
 Basketball Men's Basketball           :  3280
 Cycling Men's Road Race, Individual:  2947
 (Other)                               :247078
>
```

Figure 4 : Statistiques descriptives générales — summary(data)

1. Variables Quantitatives Continues

1.1 Variable AGE

Statistique	Valeur	Interprétation
Minimum	10 ans	Athlète le plus jeune recensé
1er Quartile (Q1)	21 ans	25% des athlètes ont moins de 21 ans
Médiane	24 ans	Valeur centrale de la distribution
Moyenne	25.56 ans	Légèrement supérieure à la médiane
3e Quartile (Q3)	28 ans	75% des athlètes ont moins de 28 ans
Maximum	97 ans	Cas exceptionnel
Valeurs manquantes	9 474 (3.49%)	Taux très faible, peu d'impact

La légère différence entre la moyenne (25.56 ans) et la médiane (24 ans) indique une légère asymétrie à droite, causée par un petit nombre d'athlètes âgés participant dans des disciplines moins physiques comme le tir ou l'équitation.

Histogramme de la distribution des âges

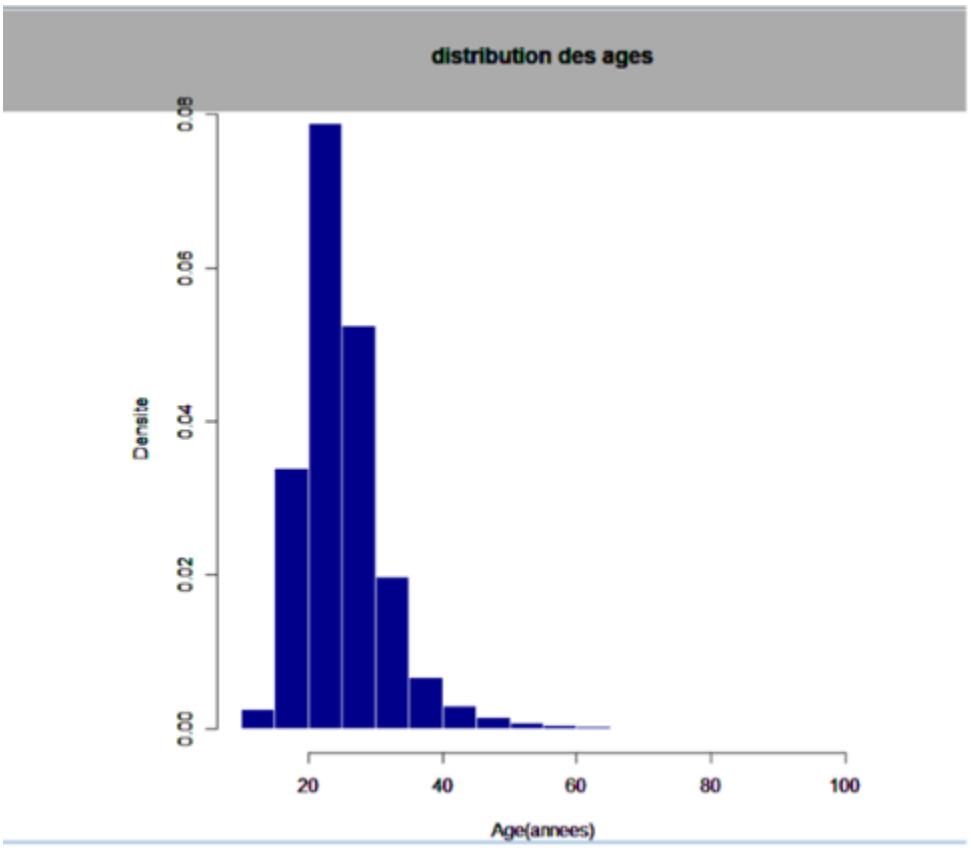


Figure 5 : Histogramme — Distribution de l'âge des athlètes olympiques

L'histogramme représente la distribution de l'âge des 271 116 athlètes. On observe clairement une distribution asymétrique à droite. La grande majorité des athlètes sont concentrés dans la tranche 20–30 ans, avec un pic très marqué autour de 23–25 ans correspondant à environ 100 000 athlètes. Au-delà de 30 ans, le nombre diminue rapidement. Très peu d'athlètes ont plus de 40 ans, et ils sont quasi inexistants après 60 ans.

Histogramme de densité avec courbe d'estimation à noyau

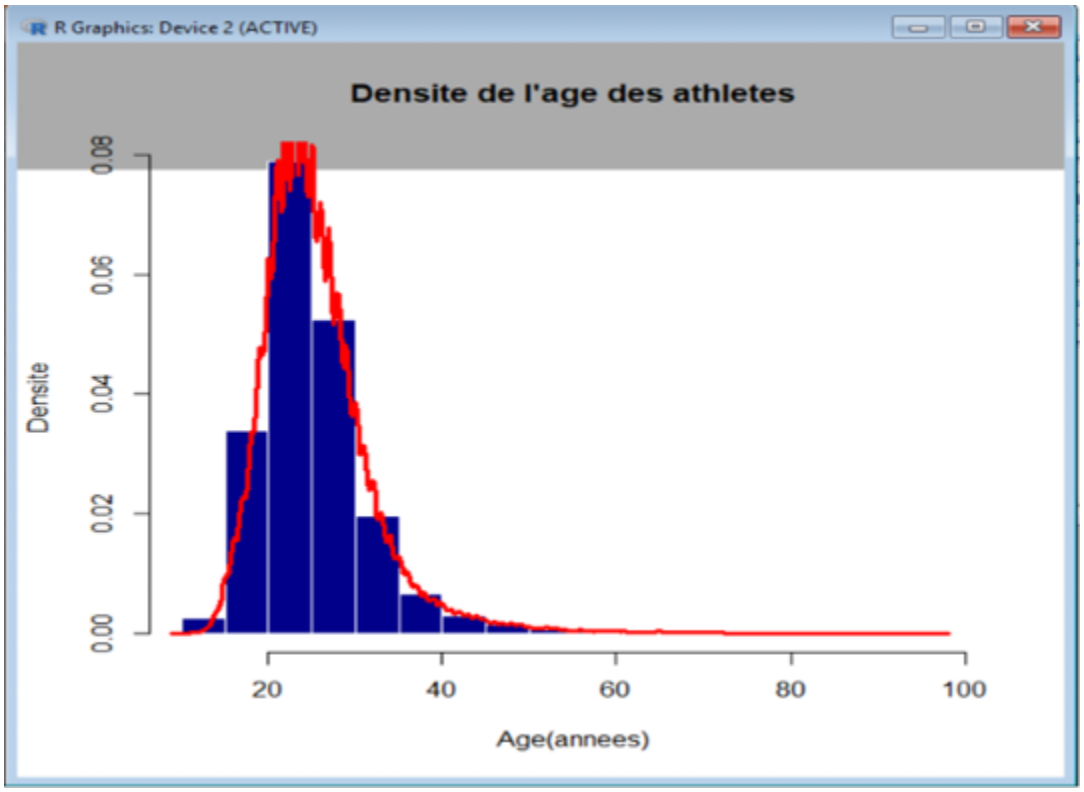


Figure 6 : Distribution de densité avec estimateur à noyau (courbe rouge)

Ce graphique superpose l'histogramme de densité (barres bleues) et la courbe de l'estimateur à noyau (ligne rouge). L'axe Y représente la densité et non les effectifs. La barre la plus haute atteint une densité de 0.08 entre 20 et 25 ans. La courbe rouge atteint son pic autour de 22–23 ans, puis redescend progressivement. Au-delà de 40 ans, la courbe s'aplatit et forme une longue queue vers la droite, témoignant de quelques rares cas de participation tardive.

Répartition par Sexe — Boîte à moustaches

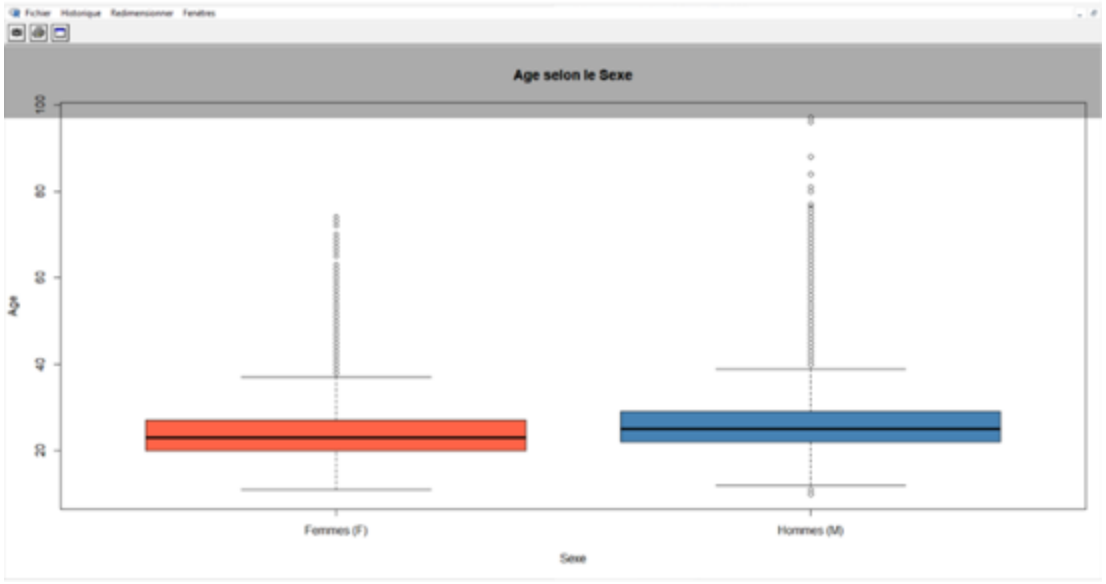


Figure 7 : Distribution de l'âge selon le Sexe

Ce graphique montre que la distribution de l'âge est pratiquement identique entre les femmes et les hommes. Les deux groupes ont une médiane similaire autour de 24–25 ans et une boîte interquartile

comprise entre 20 et 28 ans. Les moustaches s'étendent de 15 ans à environ 40–45 ans, avec quelques athlètes exceptionnels âgés de 70 à 90 ans. On conclut donc que le profil d'âge des participants est équivalent entre les deux sexes.

1.2 Variable HEIGHT (Taille)

Statistique	Valeur	Interprétation
Minimum	127 cm	
1er Quartile (Q1)	168 cm	
Médiane	175 cm	Distribution symétrique
Moyenne	175.3 cm	Quasi-identique à la médiane
3e Quartile (Q3)	183 cm	
Maximum	226 cm	
Valeurs manquantes	60 171 (22.19%)	Données historiques manquantes

La quasi-identité entre la médiane (175 cm) et la moyenne (175.3 cm) confirme une distribution symétrique et bien centrée pour la taille des athlètes olympiques.

1.3 Variable WEIGHT (Poids)

Statistique	Valeur	Interprétation
Minimum	25 kg	
1er Quartile (Q1)	60 kg	
Médiane	70 kg	Distribution symétrique
Moyenne	70.7 kg	Quasi-identique à la médiane
3e Quartile (Q3)	79 kg	
Maximum	214 kg	
Valeurs manquantes	62 875 (23.17%)	Données historiques manquantes

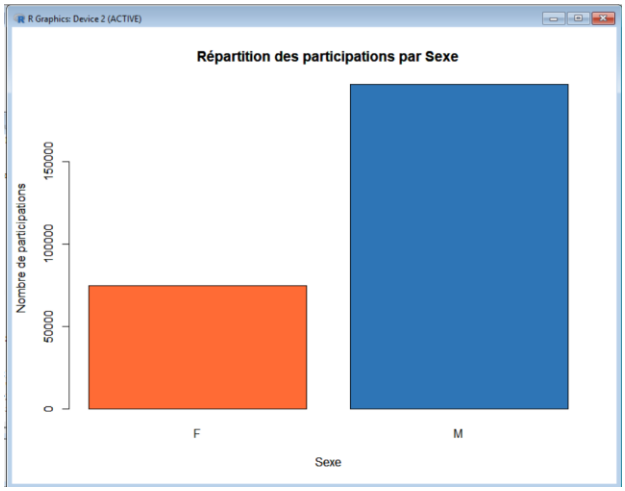
Comme pour la taille, la médiane et la moyenne sont très proches (70 kg et 70.7 kg), confirmant une distribution symétrique. Le taux élevé de valeurs manquantes (23.17%) s'explique par l'absence de ces données dans les premières décennies des Jeux.

2. Variables Qualitatives

2.1 Variable SEX (Sexe)

- **Femmes (F) :** 74 522 participations soit 27.48%
- **Hommes (M) :** 196 594 participations soit 72.52%

Les hommes représentent près des trois quarts des participations olympiques sur la période 1896–2016. Cela reflète l'ouverture progressive des Jeux Olympiques aux femmes, qui ne participaient pas ou très peu aux premières éditions.

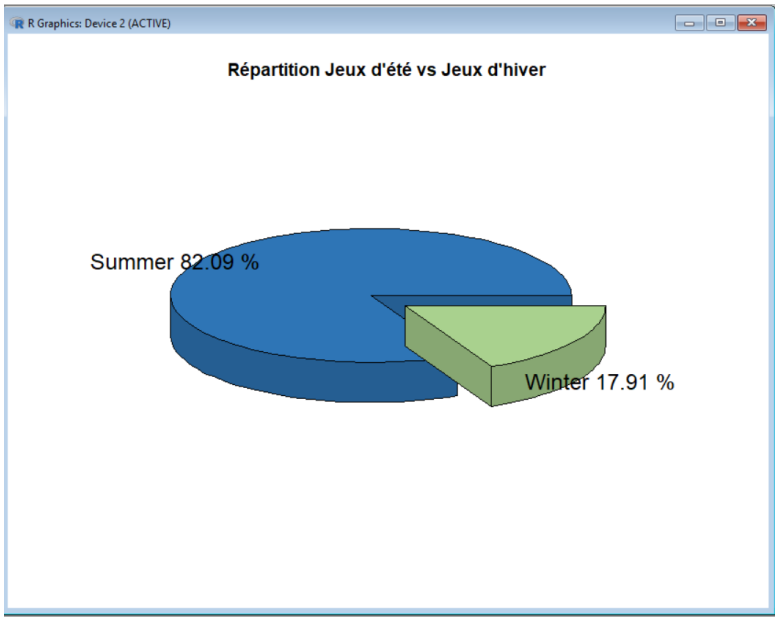


2.2 Variable SEASON (Saison)

- **Jeux d'été (Summer) :** 222 552 participations soit 82.07%
- **Jeux d'hiver (Winter) :** 48 564 participations soit 17.93%

Les Jeux d'été dominent largement le dataset en raison du nombre plus élevé de disciplines et d'athlètes engagés dans les épreuves estivales.

Pie Chart 3D : Répartition Summer vs Winter

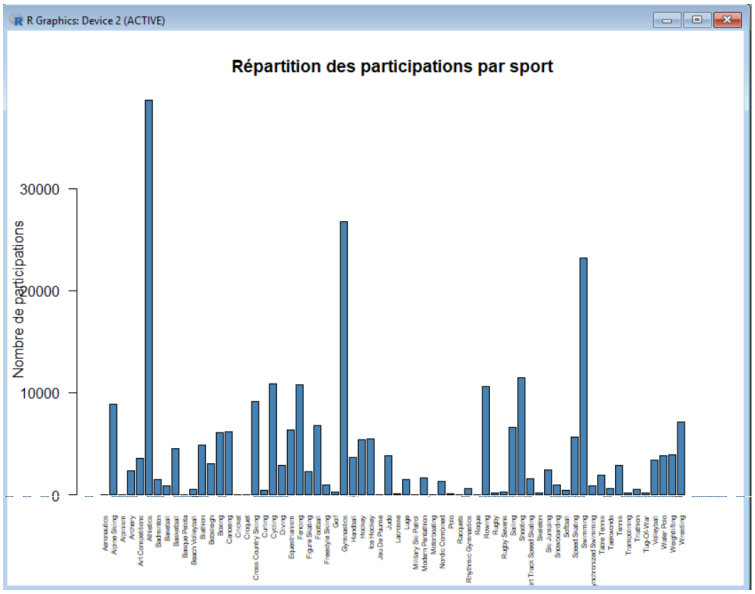


Le diagramme en secteurs 3D illustre clairement la répartition entre les deux saisons : la part bleue, représentant les Jeux d'été, occupe l'écrasante majorité du graphique avec 82,09 %, tandis que la part verte des Jeux d'hiver, détachée visuellement grâce à l'effet 3D, ne représente que 17,91 % du total des participations.

2.3 Variable SPORT

Les disciplines les plus représentées dans le dataset sont : l'Athlétisme (38 624 participations), la Gymnastique (26 707), la Natation (23 195), le Tir (11 448) et le Cyclisme (10 859). L'athlétisme domine largement grâce au très grand nombre d'épreuves individuelles qu'il regroupe.

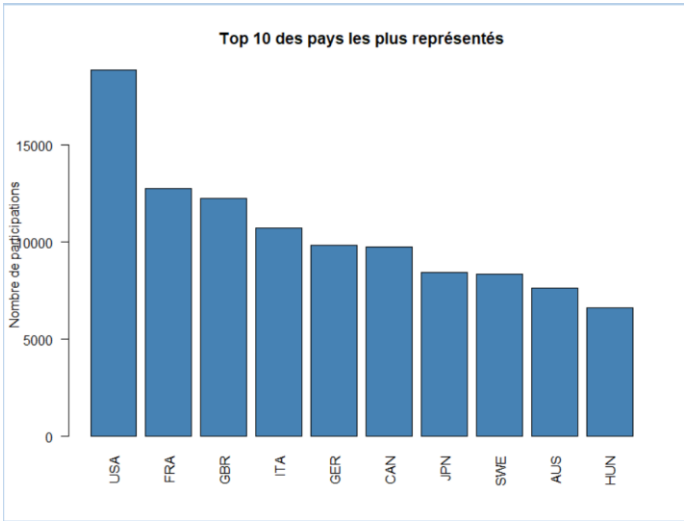
Barplot : Répartition par Sport



Le diagramme en barres confirme la domination de l'Athlétisme avec plus de 35 000 participations, loin devant la Gymnastique (~27 000) et la Natation (~23 000). La majorité des sports restent sous les 10 000 participations. Certains sports historiques comme le Roque, le Polo ou le Jeu de Paume sont quasi invisibles, témoignant de leur disparition rapide du programme olympique.

2.4 Variable NOC (Pays)

Les pays les plus représentés sont : USA (18 853), France FRA (12 758), Grande-Bretagne GBR (12 256), Italie ITA (10 715) et Allemagne GER (9 830). Les États-Unis dominent largement la participation historique aux Jeux Olympiques.

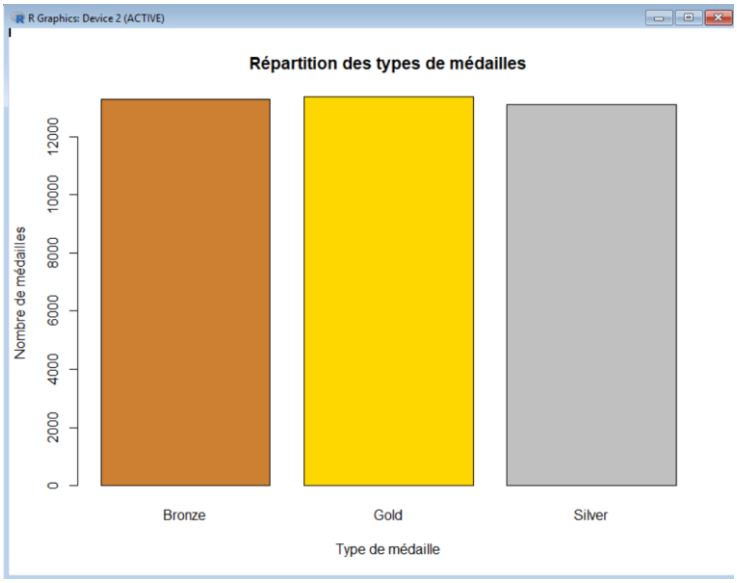


2.5 Variable MEDAL

- **Bronze :** 13 295

- **Gold :** 13 372
- **Silver :** 13 116
- **Non médaillés (NA) :** 231 333 soit 85.37%

Seulement 14.63% des participations aboutissent à une médaille. Parmi les médaillés, les trois types sont parfaitement équilibrés autour de 33% chacun, ce qui est logique puisqu'une médaille de chaque type est décernée par épreuve.



3. Variables Discrètes — Variable YEAR

3.1 Distribution Annuelle des Participants

```
> table(data$Year)

 1896  1900  1904  1906  1908  1912  1920  1924  1928  1932  1936  1948
  380  1936  1301  1733  3101  4040  4292  5693  5574  3321  7401  7480
 1952  1956  1960  1964  1968  1972  1976  1980  1984  1988  1992  1994
 9358  6434  9235  9480 10479 11959 10502  8937 11588 14676 16413  3160
 1996  1998  2000  2002  2004  2006  2008  2010  2012  2014  2016
13780  3605 13821  4109 13443  4382 13602  4402 12920  4891 13688
```

Figure 13 : Distribution annuelle du nombre de participants

Ce tableau affiche le nombre exact de participants pour chaque édition des Jeux Olympiques. Les données commencent en 1896 avec 380 athlètes et s'étendent jusqu'en 2016 avec 13 688 athlètes. On observe une croissance continue du nombre de participants. Les années 1900–1936 montrent une participation modérée. À partir des années 1950, une forte augmentation commence. Le pic maximal est atteint en 1996 avec 13 443 athlètes, suivi d'une légère stabilisation.

3.2 Histogramme de l'Évolution

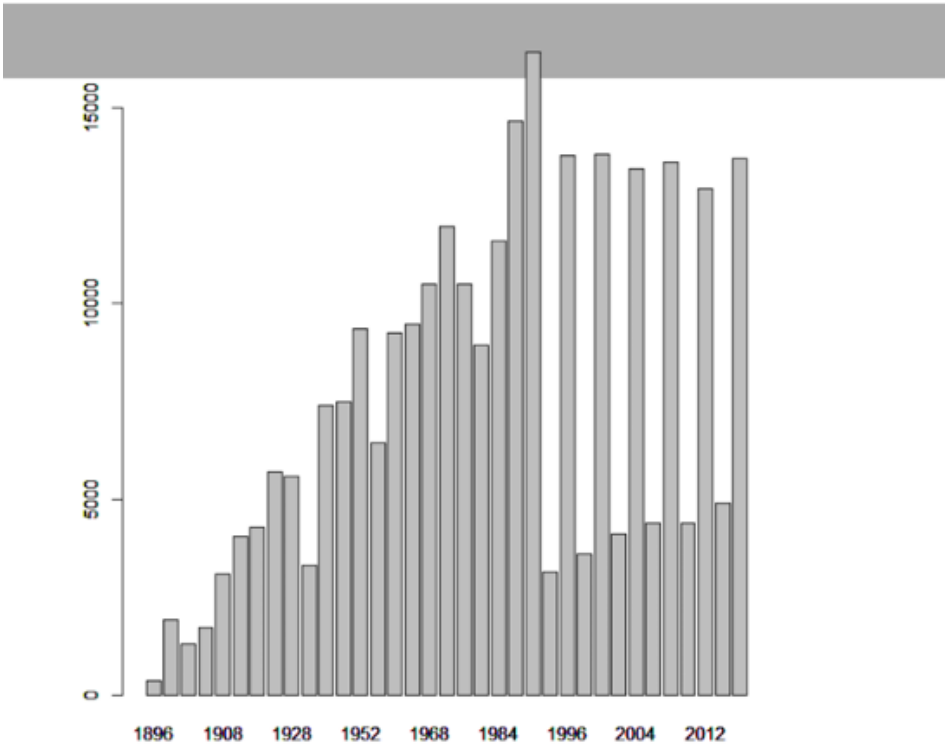


Figure 14 : Histogramme — Évolution du nombre de participants aux JO

L'histogramme visualise le nombre total de participants pour chaque édition des Jeux Olympiques. On distingue trois phases distinctes :

- **Phase 1 (1896–1928) :** Participation faible en croissance lente.
- **Phase 2 (1928–1996) :** Croissance accélérée. Le nombre de participants double puis triple progressivement.
- **Phase 3 (1996–2016) :** Plateau à un niveau élevé. Après le pic de 1996 avec plus de 15 000 participants, la participation se stabilise entre 12 000 et 14 000 athlètes.

3.3 Niveaux de la Variable Year

```
> nb=(levels(factor(data$Year)))
> nb
 [1] "1896" "1900" "1904" "1906" "1908" "1912" "1920" "1924" "1928" "1932"
[11] "1936" "1948" "1952" "1956" "1960" "1964" "1968" "1972" "1976" "1980"
[21] "1984" "1988" "1992" "1994" "1996" "1998" "2000" "2002" "2004" "2006"
[31] "2008" "2010" "2012" "2014" "2016"
```

Figure 15 : Tableau des niveaux de la variable Year

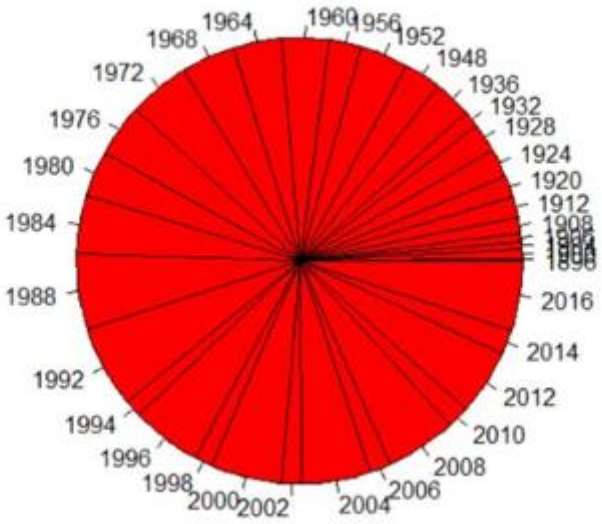


Figure 16 : Diagramme circulaire — Éditions des Jeux Olympiques

Le dataset couvre 31 éditions des Jeux Olympiques, de 1896 à 2016. Les Jeux sont tenus régulièrement tous les 4 ans depuis 1896. On note l'absence des années 1916, 1940 et 1944, qui correspondent aux éditions annulées en raison des deux guerres mondiales.

Partie III — Analyse Bivariée

On dispose de trois variables quantitatives dans le dataset des Jeux Olympiques : l'âge (Age), la taille (Height) et le poids (Weight) des athlètes. L'analyse bivariée permet d'étudier les relations entre ces variables deux à deux.

1. Variables Quantitatives vs Quantitatives

1.1 Matrice de Corrélation

```
> cor(quant, use="complete.obs")
              Age    Height    Weight
Age    1.0000000 0.1416845 0.2120407
Height 0.1416845 1.0000000 0.7965726
Weight 0.2120407 0.7965726 1.0000000
>
```

Figure 17 : Matrice de corrélation — cor(quant, use='complete.obs')

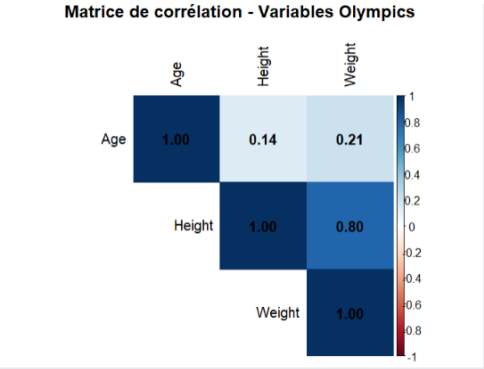


Figure 18 : Visualisation de la matrice de corrélation (corrplot)

La matrice de corrélation obtenue avec cor() sous R révèle les relations suivantes :

- **Entre la taille et le poids (0.80) :** c'est la corrélation la plus forte. Elle est positive et élevée, ce qui signifie que quand la taille augmente, le poids augmente aussi. Ce résultat est tout à fait logique et attendu biologiquement.
- **Entre l'âge et le poids (0.21) :** la corrélation est faible. Il existe un très léger lien entre les deux variables, mais il est insuffisant pour conclure à une vraie relation linéaire. L'âge n'explique donc pas le poids d'un athlète.
- **Entre l'âge et la taille (0.14) :** la corrélation est quasi nulle. Il n'existe aucune relation linéaire entre l'âge et la taille des athlètes dans ce dataset.

Conclusion : la seule relation significative dans notre dataset est celle entre la taille et le poids.

1.2 Nuage de Points : Taille vs Poids

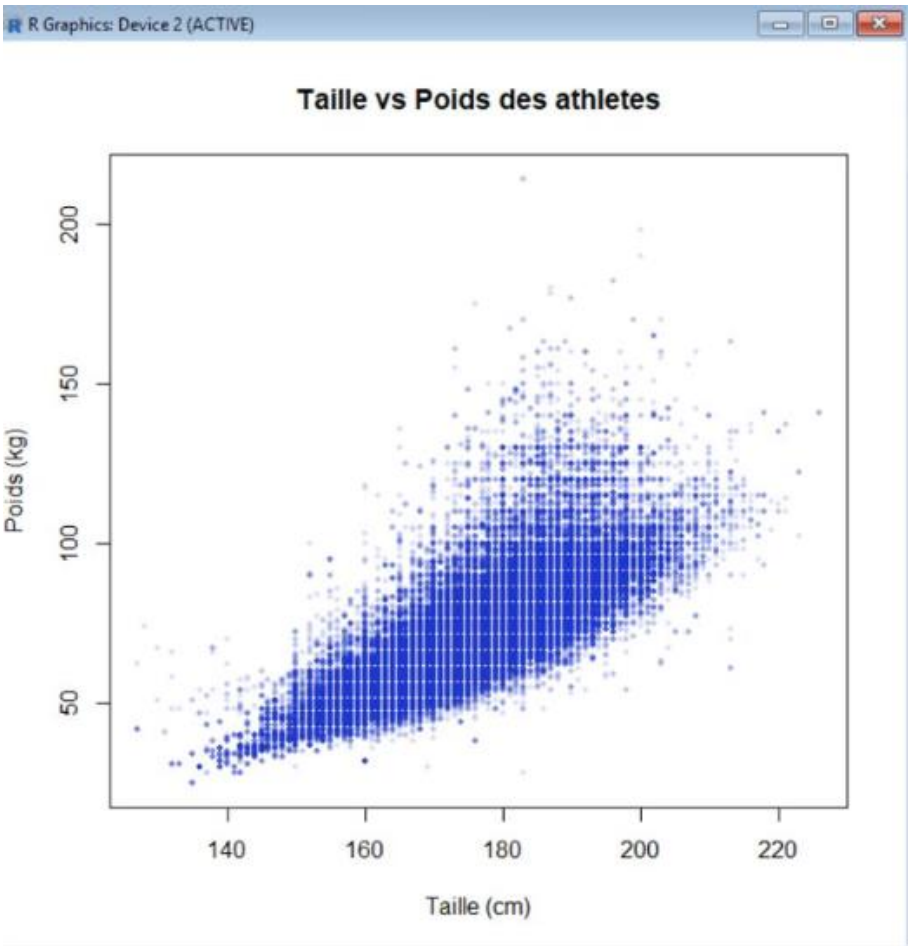


Figure 19 : Nuage de points — Taille vs Poids des athlètes

Le graphique représente la relation entre la taille (en cm) et le poids (en kg) des athlètes olympiques. Chaque point correspond à un athlète du dataset. On observe clairement une tendance positive : plus la taille augmente, plus le poids tend à augmenter également. Cette relation visuelle confirme parfaitement le coefficient de corrélation de 0.80 obtenu précédemment. La majorité des athlètes se concentre entre 160 cm et 190 cm pour la taille, et entre 60 kg et 100 kg pour le poids.

1.3 Nuage de Points : Taille vs Poids par Sexe

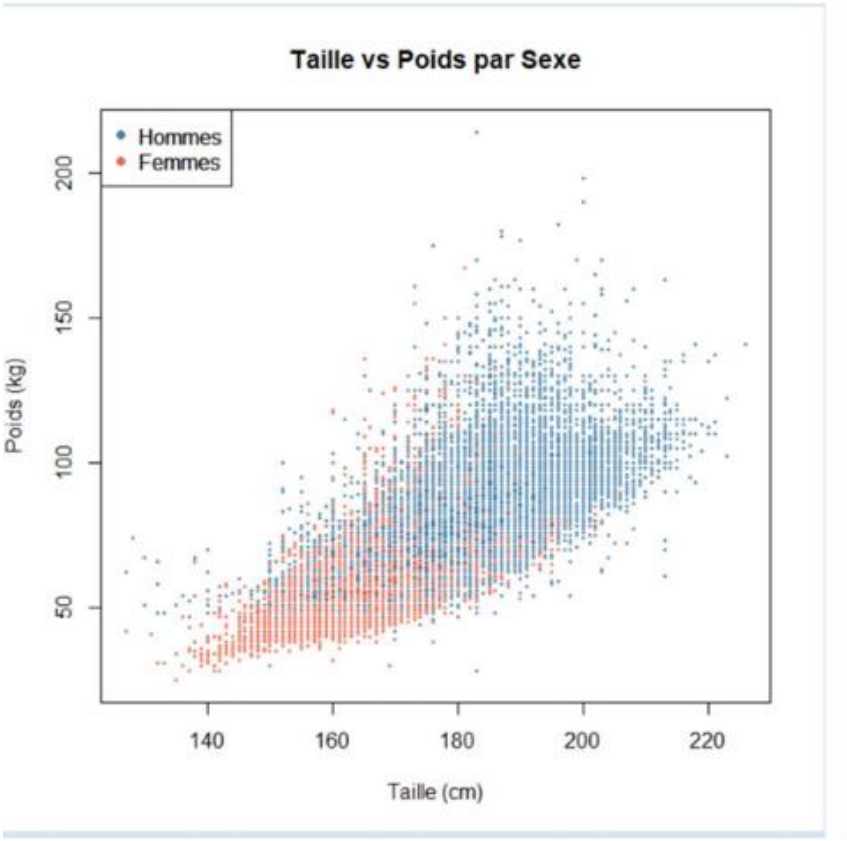


Figure 20 : Nuage de points — Taille vs Poids par Sexe

Ce graphique reprend la même relation mais en distinguant les deux sexes. On remarque clairement une séparation entre les deux groupes :

- **Femmes :** concentrées entre 155 cm et 175 cm (taille) et entre 45 kg et 75 kg (poids).
- **Hommes :** situés plutôt entre 170 cm et 200 cm, avec un poids allant de 70 kg à 130 kg.

Les deux nuages se chevauchent légèrement autour de 170–175 cm, ce qui signifie qu'à taille égale, certains hommes et certaines femmes peuvent présenter des profils morphologiques similaires.

1.4 Estimation Locale de Densité : Taille vs Poids

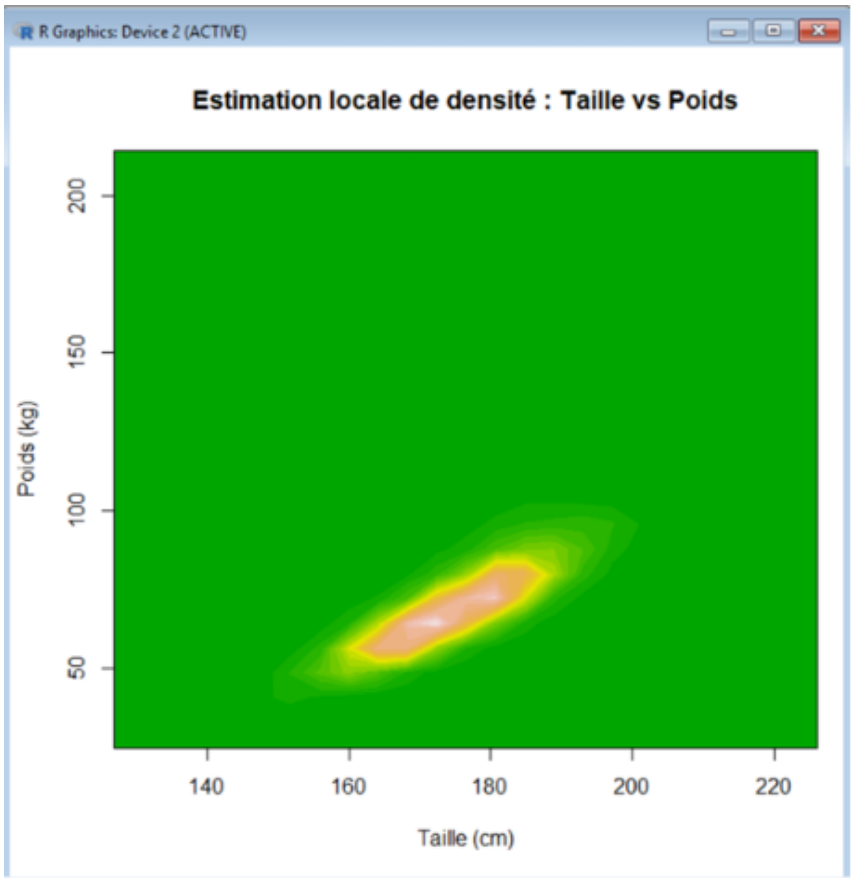


Figure 21 : Estimation locale de densité — Taille vs Poids (filled.contour)

Ce graphique représente la densité des athlètes olympiques selon leur taille et leur poids. La zone la plus dense, représentée en blanc et en orange au centre, se situe autour de 170–180 cm pour la taille et 60–75 kg pour le poids. Autour de ce noyau central, la densité diminue progressivement vers le jaune puis le vert, confirmant que les profils extrêmes (très grands et très lourds, ou très petits et très légers) sont beaucoup plus rares.

1.5 Régression Linéaire : Taille ~ Poids

```
> model = lm(data$Height ~ data$Weight)
> summary(model)

Call:
lm(formula = data$Height ~ data$Weight)

Residuals:
     Min       1Q   Median       3Q      Max
-76.307  -3.820   0.138   4.138  43.309

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 1.340e+02  7.057e-02  1898.2   <2e-16 ***
data$Weight 5.857e-01  9.786e-04   598.5   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.378 on 206851 degrees of freedom
  (64263 observations effacées parce que manquantes)
Multiple R-squared:  0.634,     Adjusted R-squared:  0.634
F-statistic: 3.582e+05 on 1 and 206851 DF,  p-value: < 2.2e-16

>
```

Figure 22 : Résultats de la régression linéaire — summary(lm(...))

Le modèle utilisé est lm(data$Height ~ data$Weight), ce qui signifie que la variable Height (taille) est expliquée en fonction de la variable Weight (poids). L'équation du modèle obtenue est la suivante :

$$\text{Taille} = 134 + 0.586 \times \text{Poids}$$

Les résidus varient de -76.307 à 43.309, avec une médiane très proche de zéro (0.138), signe d'un bon ajustement du modèle. Le modèle comporte deux coefficients :

- **L'intercept (134) :** lorsque le poids est égal à zéro, la taille estimée est de 134 cm.
- **Le coefficient du poids (0.586) :** pour chaque kilogramme supplémentaire, la taille augmente en moyenne de 0.586 cm. Ce coefficient positif confirme la relation positive entre les deux variables.
- **P-value < 2e-16 :** bien en dessous du seuil de 0.05, le modèle est statistiquement significatif. La relation observée n'est pas due au hasard.
- **R^2 = 0.634 :** le modèle explique 63.4% de la variance de la taille. Les 36.6% restants sont expliqués par d'autres facteurs comme le sexe ou la discipline sportive.

1.6 Représentation Graphique de la Régression

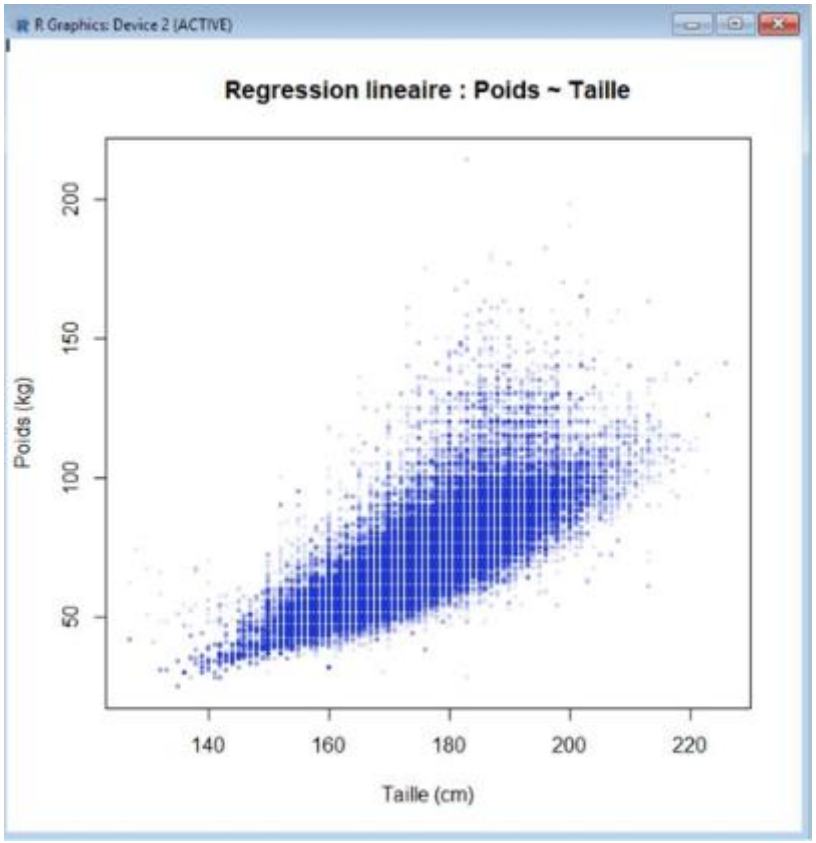


Figure 23 : Droite de régression superposée au nuage de points

Le graphique représente la droite de régression linéaire superposée au nuage de points. La droite suit bien la tendance générale du nuage en passant par le centre de la distribution, confirmant

visuellement que le modèle linéaire est adapté. Sa pente positive est cohérente avec le coefficient de régression de 0.586.

1.7 Intervalles de Confiance

```
> t.test(data$Height)

        One Sample t-test

data:  data$Height
t = 7656.2, df = 210944, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 175.2941 175.3839
sample estimates:
mean of x
  175.339

> t.test(data$Weight)

        One Sample t-test

data:  data$Weight
t = 2248.7, df = 208240, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 70.64077 70.76402
sample estimates:
mean of x
 70.70239

>
```

Figure 24 : Intervalles de confiance à 95% pour la Taille et le Poids

L'intervalle de confiance permet, à partir d'un échantillon, d'estimer la vraie valeur de la moyenne de toute la population avec un certain niveau de confiance. Nous avons appliqué la fonction t.test() sur les deux variables :

- **Taille :** Moyenne de 175.339 cm, intervalle de confiance à 95% = [175.29 → 175.38]. Intervalle très étroit, estimation très précise.
- **Poids :** Moyenne de 70.70 kg, intervalle de confiance à 95% = [70.64 → 70.76]. Intervalle très étroit, estimation très fiable.

La précision des intervalles est directement liée au très grand nombre d'observations (plus de 200 000), ce qui réduit considérablement la marge d'erreur.

1.8 Régression avec Intervalle de Confiance

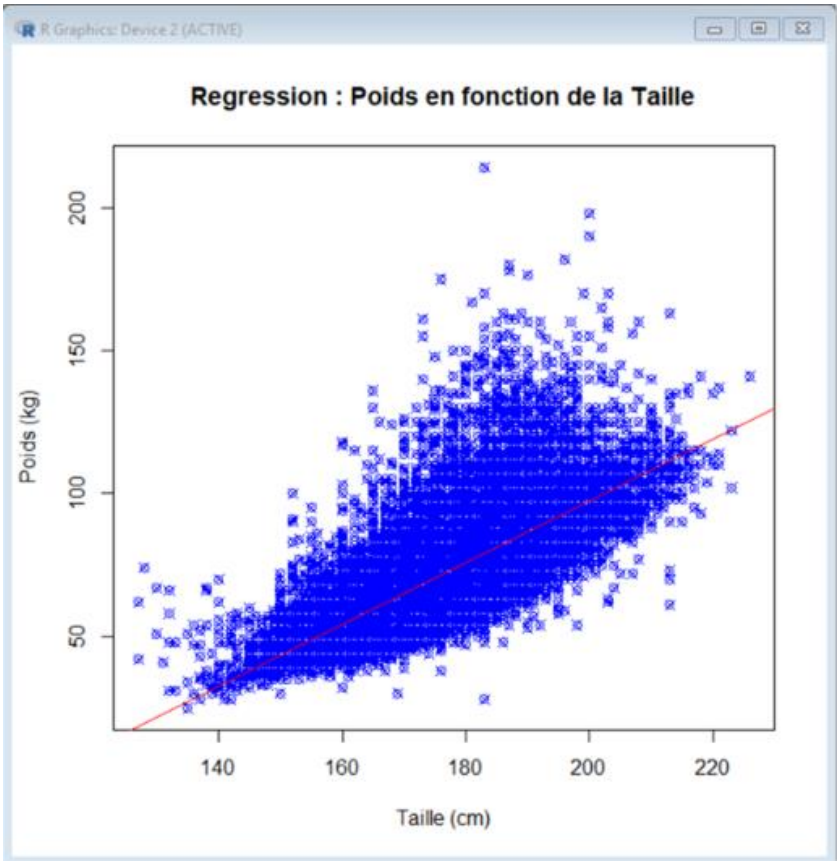


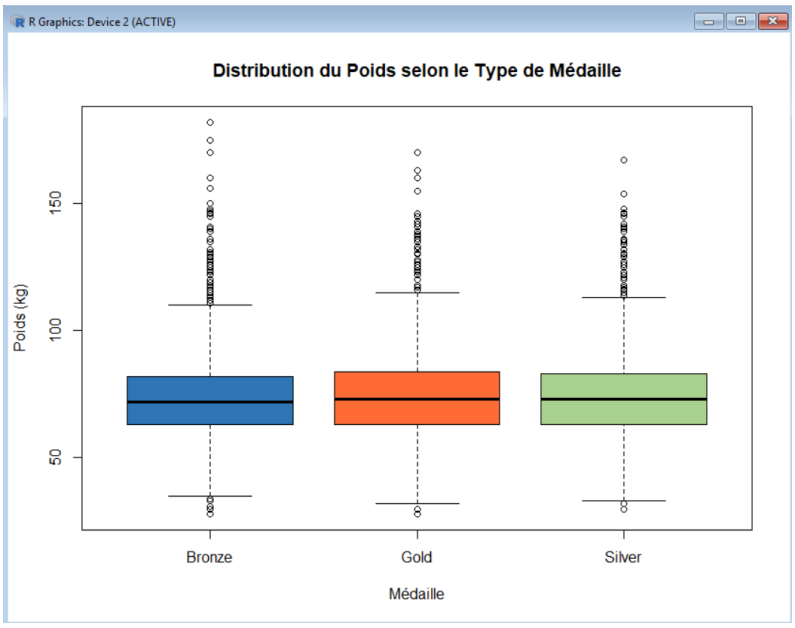
Figure 25 : Régression avec intervalle de confiance (lignes rouges)

Ce graphique reprend la droite de régression entre la taille et le poids des athlètes olympiques, en y ajoutant l'intervalle de confiance représenté par les deux lignes rouges encadrant la droite. L'intervalle est très resserré autour de la droite grâce à la très grande taille de l'échantillon, confirmant la fiabilité du modèle.

2. Variables Quantitative × Qualitative

La variable POIDS (Weight) est une variable quantitative continue exprimée en kilogrammes, et la variable MÉDAILLE (Medal) est une variable qualitative ordinale à trois modalités : Bronze, Gold et Silver. Nous avons choisi ces deux variables car il est pertinent de se demander si le profil de poids d'un athlète influence le type de médaille qu'il obtient.

2.1-Distribution du Poids selon le Type de Médaille obtenue



La boîte à moustaches représente la distribution du poids des athlètes médaillés selon le type de médaille obtenue. On observe que les trois boîtes sont très similaires : les trois médianes se situent autour de 70 kg et les boîtes interquartiles s'étendent approximativement entre 60 kg et 80 kg pour les trois groupes. Cela suggère visuellement que le poids moyen des athlètes est globalement équivalent quel que soit le type de médaille obtenue.

2.2-ANOVA — Distribution du Poids selon le Type de Médaille

```
> anova_result <- aov(Weight ~ Medal, data=data_medailles)
> summary(anova_result)
              Df  Sum Sq Mean Sq F value  Pr(>F)
Medal          2    2778  1389.2   6.163 0.00211 **
Residuals  30453 6864245   225.4
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
9327 observations effacées parce que manquantes
>
```

L'ANOVA révèle un F value = 6.163 avec une p-value = 0.00211, largement inférieure au seuil de 0.05. On rejette donc l'hypothèse nulle d'égalité des moyennes entre les trois groupes et on conclut qu'il existe une différence statistiquement significative du poids moyen selon le type de médaille obtenue.

2.3- Test de Kruskal-Wallis

```
> kruskal.test(Weight ~ Medal, data=data_medailles)

        Kruskal-Wallis rank sum test

data:  Weight by Medal
Kruskal-Wallis chi-squared = 14.806, df = 2, p-value = 0.0006094
```

Le test de Kruskal-Wallis confirme le résultat de l'ANOVA avec un chi-squared = 14.806, df = 2 et une p-value = 0.0006094, inférieure au seuil de 0.05. La p-value étant très inférieure au seuil de

0.05, on rejette l'hypothèse nulle et on conclut qu'il existe une différence significative du poids entre les trois types de médailles Bronze, Gold et Silver.

2.4- Test du Khi-deux — Vérification des conditions

```
> chisq.test(t3)

        Pearson's Chi-squared test

data:  t3
X-squared = NaN, df = 2, p-value = NA

Message d'avis :
Dans chisq.test(t3) : L'approximation du Chi-2 est peut-être incorrecte
>
```

Le test du khi-deux ne peut pas être appliqué ici car certaines cases du tableau contiennent des effectifs trop faibles (la colonne Silver = 0), ce qui justifie le recours au test exact de Fisher.

2.5- Test exact de Fisher

```
> fisher.test(t3)

        Fisher's Exact Test for Count Data

data:  t3
p-value = 0.7449
alternative hypothesis: two.sided
```

Le test de Fisher donne une p-value = 0.7449, largement supérieure au seuil de 0.05. On conclut qu'il n'existe pas de lien statistiquement significatif entre la catégorie de poids de l'athlète (Leger/Lourd) et le type de médaille obtenue (Bronze/Gold) sur ce sous-échantillon.

2.6-Conclusion

L'analyse bivariée a mis en évidence une forte corrélation positive entre la taille et le poids des athlètes (r = 0.80), confirmée par le modèle de régression linéaire (Taille = 134 + 0.586 × Poids, R^2 = 0.634). Pour la relation entre variables quantitatives et qualitatives, l'ANOVA (p-value = 0.00211) et le test de Kruskal-Wallis (p-value = 0.0006094) ont confirmé qu'il existe une différence significative du poids selon le type de médaille. Enfin, le test exact de Fisher a conclu à l'indépendance entre le poids de l'athlète et le type de médaille sur le sous-échantillon étudié.

Partie IV — Analyse Multivariée

L'analyse multivariée permet d'étudier simultanément plusieurs variables pour en extraire des structures globales. Nous appliquons deux méthodes complémentaires : l'Analyse en Composantes Principales (ACP) pour les variables quantitatives, et l'Analyse Factorielle des Correspondances (AFC) pour les variables qualitatives.

I. Analyse en Composantes Principales (ACP)

I.1 Présentation et Objectif

L'Analyse en Composantes Principales (ACP) est une méthode statistique qui permet de résumer et de visualiser l'information contenue dans un dataset comportant plusieurs variables quantitatives. Lorsque les données comprennent plus de deux variables, il devient impossible de visualiser toutes les relations en même temps. L'ACP résout ce problème en réduisant la dimensionnalité tout en conservant le maximum d'information.

Dans notre cas, nous disposons de trois variables quantitatives : Age, Height et Weight. L'objectif est de réduire ces trois dimensions en quelques composantes principales tout en perdant le minimum d'information, et d'identifier les relations structurelles entre ces variables sur les 120 ans d'histoire des Jeux Olympiques.

Avant de réaliser l'ACP, nous avons nettoyé les données en supprimant les observations ayant des valeurs manquantes. Cela nous a donné 206 165 observations complètes sur les 271 116 initiales, soit 76% du dataset initial.

I.2 Matrice de Corrélation — Rappel

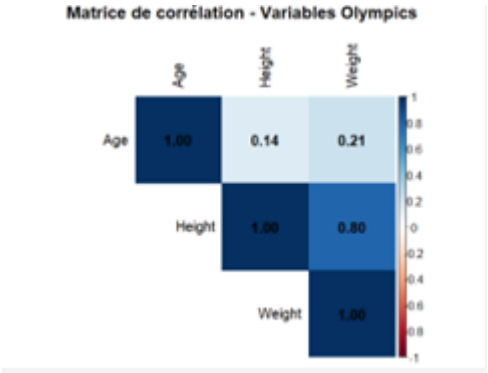


Figure 26 : Matrice de corrélation des variables quantitatives

Avant de lancer l'ACP, nous rappelons la matrice de corrélation entre les trois variables :

	Age	Height	Weight
Age	1.000	0.142	0.212
Height	0.142	1.000	0.797
Weight	0.212	0.797	1.000

- **Height et Weight (0.797) :** corrélation très élevée et positive — relation forte biologiquement logique.
- **Age et Height (0.142) :** corrélation quasi nulle — l'âge n'a aucune influence sur la taille.
- **Age et Weight (0.212) :** corrélation faible — l'âge n'explique pas non plus le poids.

Ces résultats justifient le recours à l'ACP pour mieux comprendre la structure globale des données : Height et Weight partagent une dimension commune (corpulence), tandis qu'Age est indépendante.

I.3 Valeurs Propres et Scree Plot

Les valeurs propres mesurent la quantité d'information retenue par chaque composante principale. Les résultats obtenus sont :

```
> eigval
      eigenvalue variance.percent cumulative.variance.percent
Dim.1  1.8687116        62.290386                    62.29039
Dim.2  0.9311149        31.037162                    93.32755
Dim.3  0.2001736         6.672452                   100.00000
```

Dimension	Valeur propre	Variance expliquée (%)	Variance cumulée (%)
Dim.1	1.8687	62.29%	62.29%
Dim.2	0.9311	31.04%	93.33%
Dim.3	0.2002	6.67%	100.00%

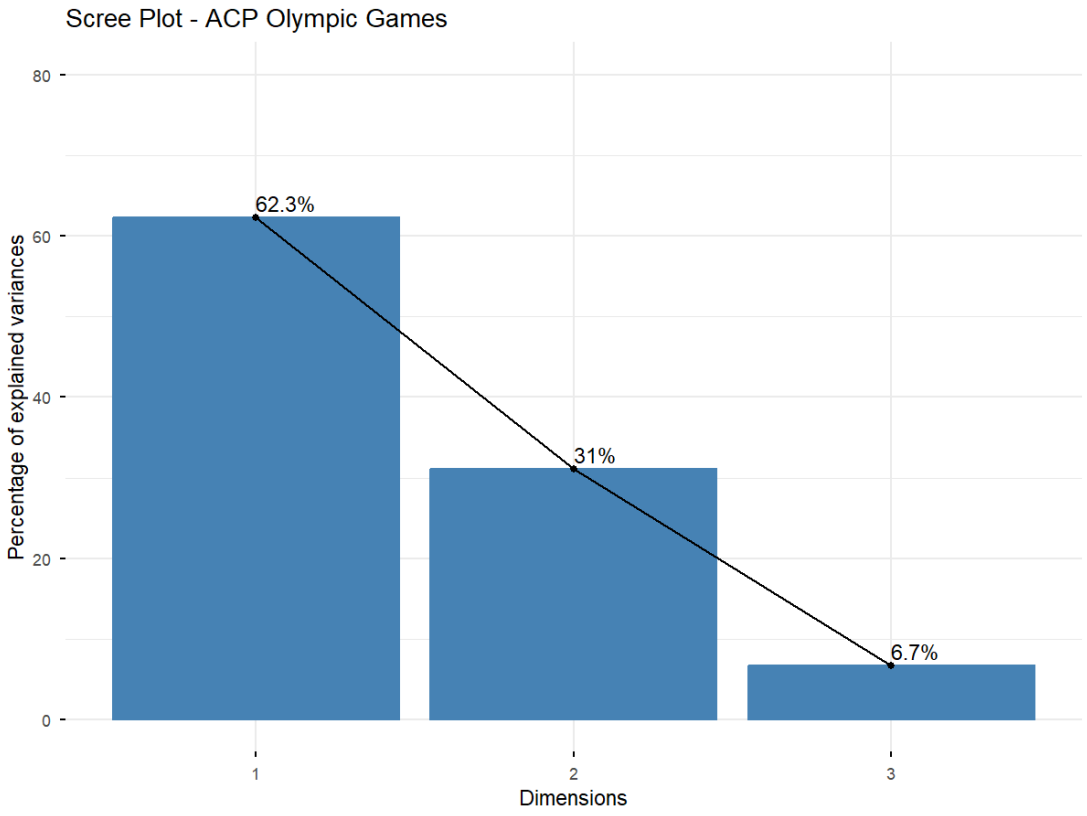


Figure 27 : Scree Plot — Valeurs propres de l'ACP

Interprétation des valeurs propres :

- **Dimension 1 (62.29%) :** explique à elle seule plus de la moitié de la variance totale. C'est la composante principale qui porte le plus d'information.
- **Dimension 2 (31.04%) :** apporte 31% supplémentaires. Ensemble avec la Dim.1, elles expliquent 93.33% de la variance.
- **Dimension 3 (6.67%) :** n'apporte que très peu d'information supplémentaire. Elle est donc négligeable.

Le Scree Plot confirme ce résultat : la courbe montre une chute nette après la première dimension, puis se stabilise. Il suffit donc de retenir deux composantes principales pour représenter fidèlement les données.

I.4 Cercle de Corrélation des Variables

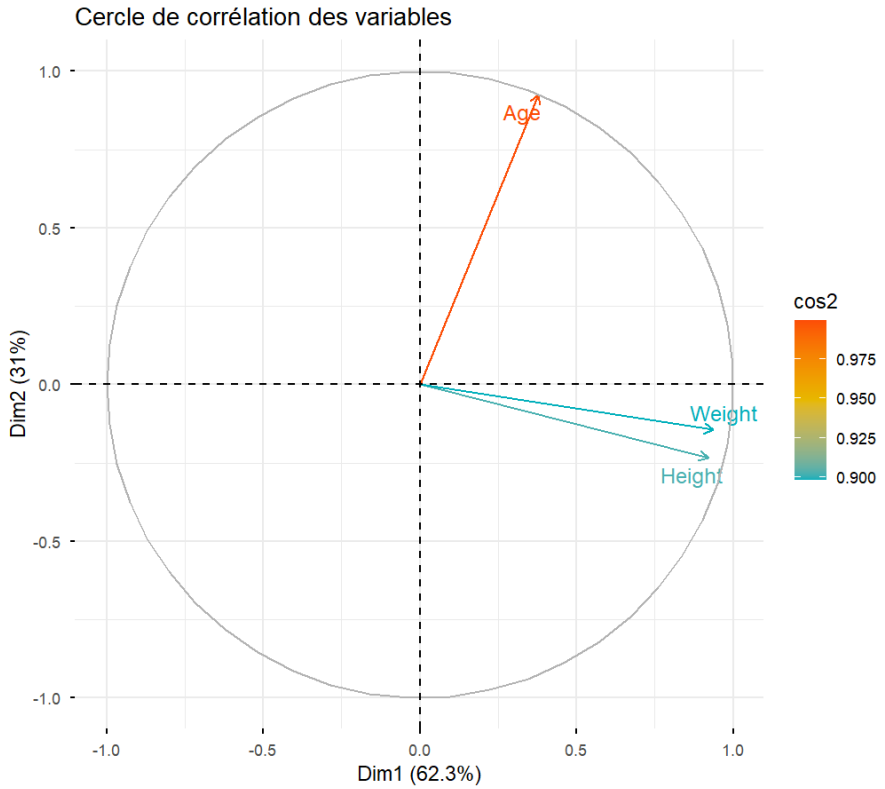


Figure 28 : Cercle de corrélation des variables (fviz_pca_var)

Le cercle de corrélation permet de visualiser les relations entre les variables et les composantes principales. Les vecteurs représentent les variables, et leur direction et longueur informent sur leurs corrélations. Interprétation :

- **Height et Weight :** forment un angle aigu, confirmant leur corrélation positive très élevée (0.797). Elles sont presque alignées et contribuent fortement à la Dimension 1.
- **Age :** est pratiquement perpendiculaire à Height et Weight, ce qui confirme qu'elle est indépendante de ces deux variables. Age contribue principalement à la Dimension 2.
- **Longueur des vecteurs :** les trois vecteurs sont proches de la circonférence du cercle, ce qui indique une bonne qualité de représentation sur les axes retenus.

I.5 Qualité de Représentation (cos²)

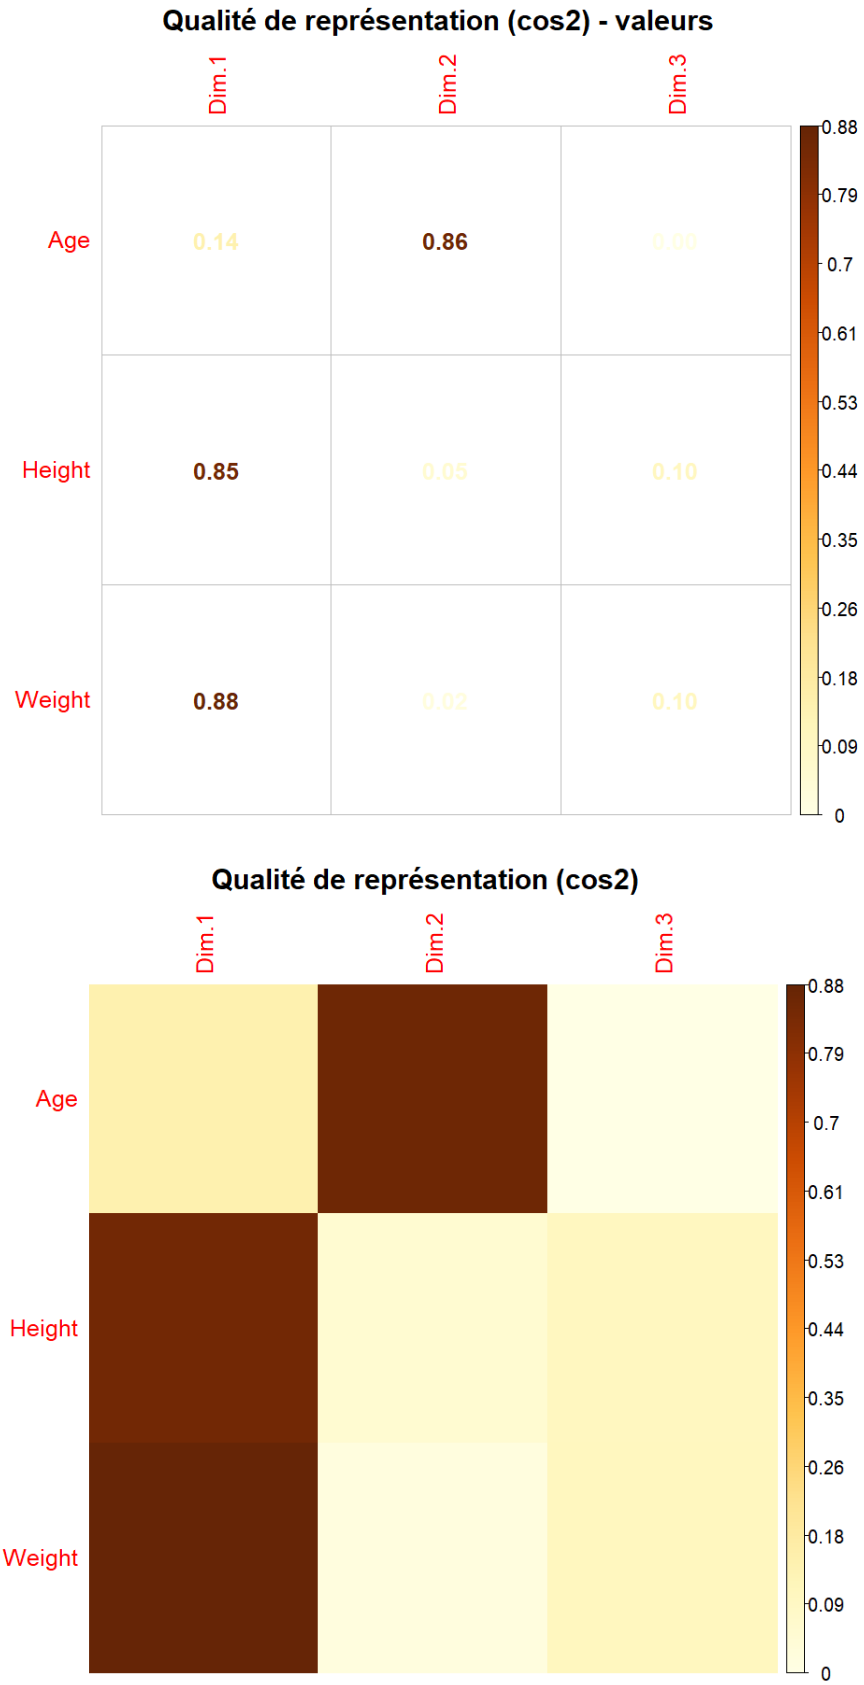


Figure 29 : Qualité de représentation des variables

Le cos² mesure la qualité de représentation d'une variable sur chaque axe. Plus il est proche de 1, meilleure est la représentation.

```
> print(graph$cos2)
            Dim.1       Dim.2        Dim.3
Age    0.1434989 0.85564855 0.0008525637
Height 0.8477426 0.05463924 0.0976181705
Weight 0.8774701 0.02082706 0.1017028382
> png("cos2.png"  width=1200  height=900  res=
```

Variable	cos² Dim.1	cos² Dim.2	cos² Dim.3
Age	0.143	0.856	0.001
Height	0.848	0.055	0.098
Weight	0.877	0.021	0.102

- **Height et Weight sur Dim.1 :** cos² très élevés (0.848 et 0.877). Ces deux variables sont excellemment représentées sur le premier axe.
- **Age sur Dim.2 :** cos² de 0.856. L'axe 2 capture presque toute l'information relative à l'âge des athlètes.
- **Dim.3 :** valeurs cos² très faibles pour toutes les variables, confirmant qu'elle n'apporte pas d'information utile.

I.6 Contributions des Variables

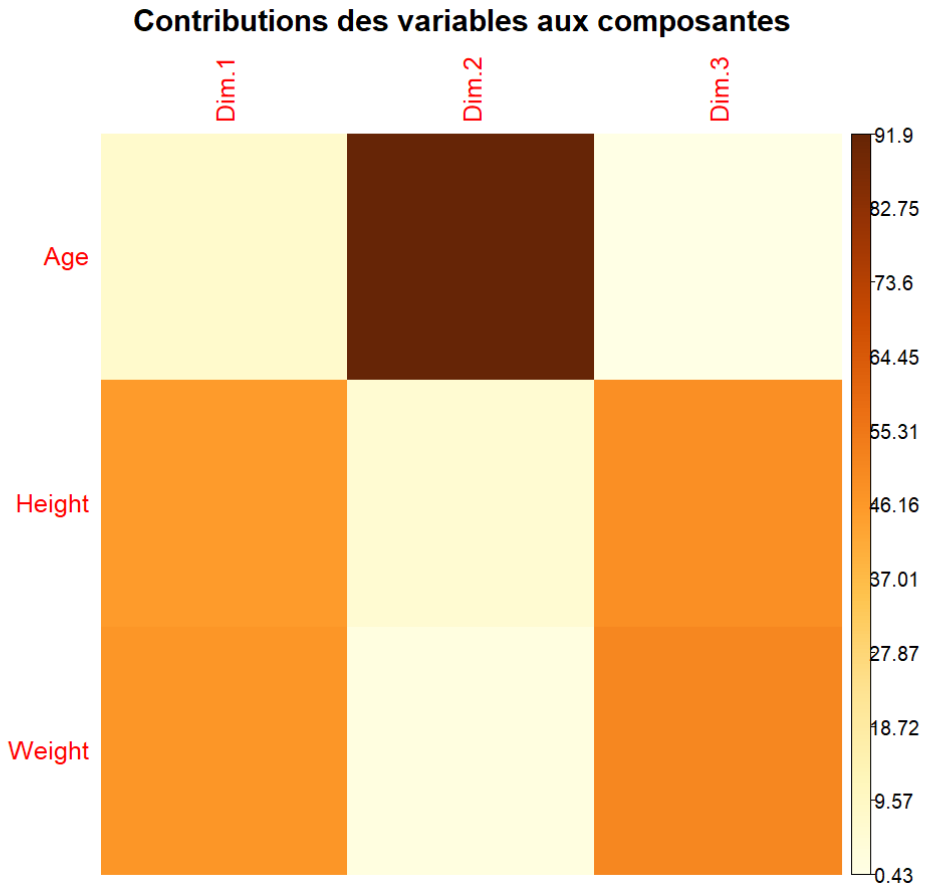


Figure 30 : Contributions des variables aux composantes principales

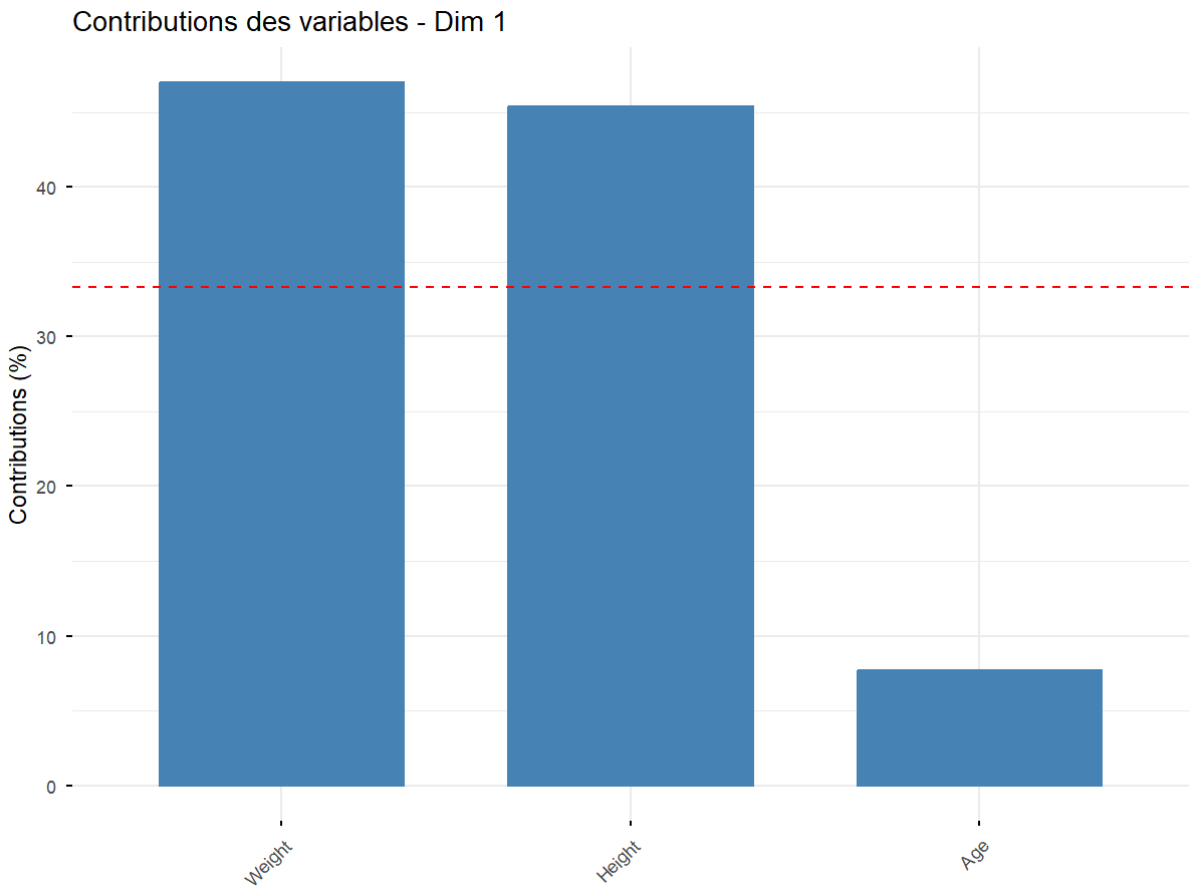


Figure 31 : Contributions des variables — Dim. 1

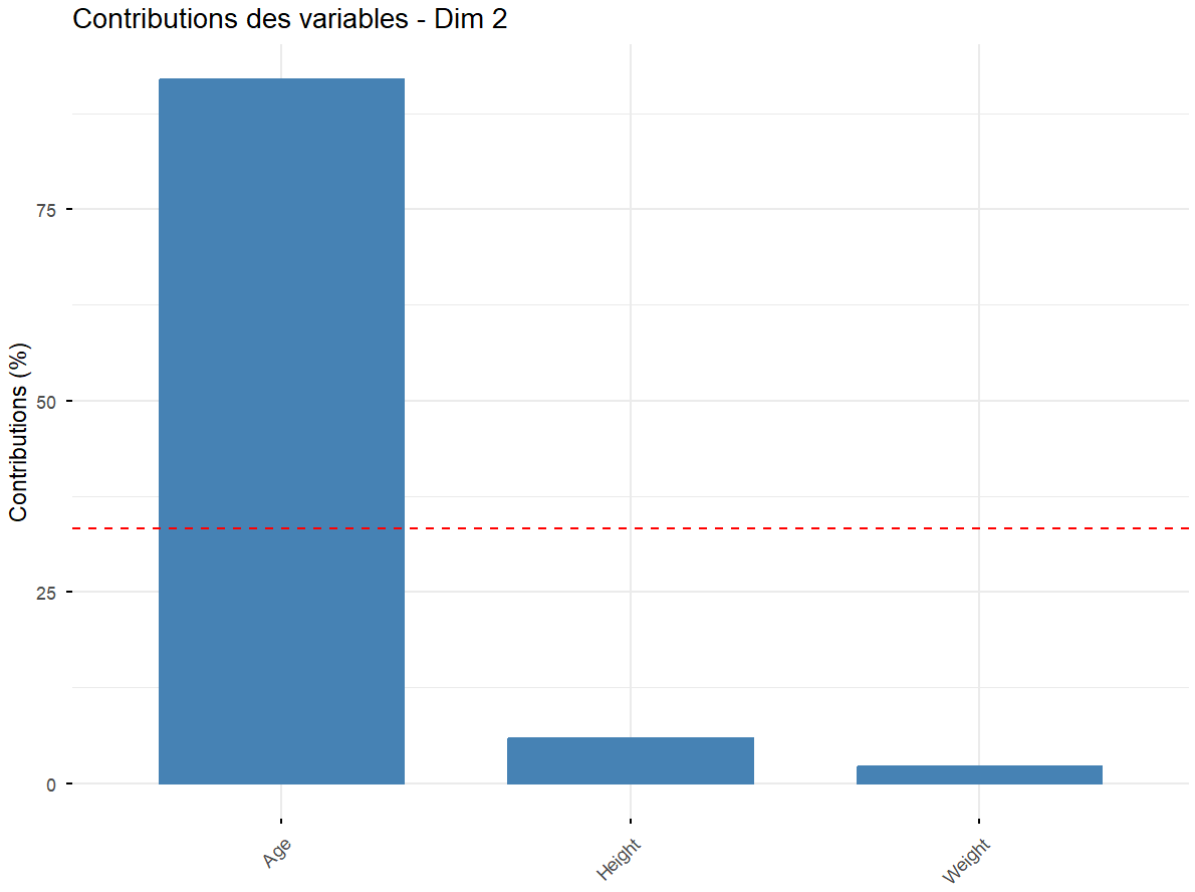


Figure 32 : Contributions des variables — Dim. 2

Les contributions indiquent l'importance de chaque variable dans la construction de chaque composante principale :

- **Dimension 1 (axe morphologique) :** Height et Weight contribuent de manière dominante et quasi équivalente (respectivement 45.4% et 47.0%). Cet axe capture la corpulence générale de l'athlète. Plus un athlète est positionné à droite sur cet axe, plus il est grand et lourd.
- **Dimension 2 (axe d'expérience) :** Age est la variable qui contribue le plus à cet axe (91.9%). Cet axe sépare les athlètes selon leur âge, les plus âgés se positionnant en haut ou en bas du graphique selon leur profil.

I.7 Graphique des Individus

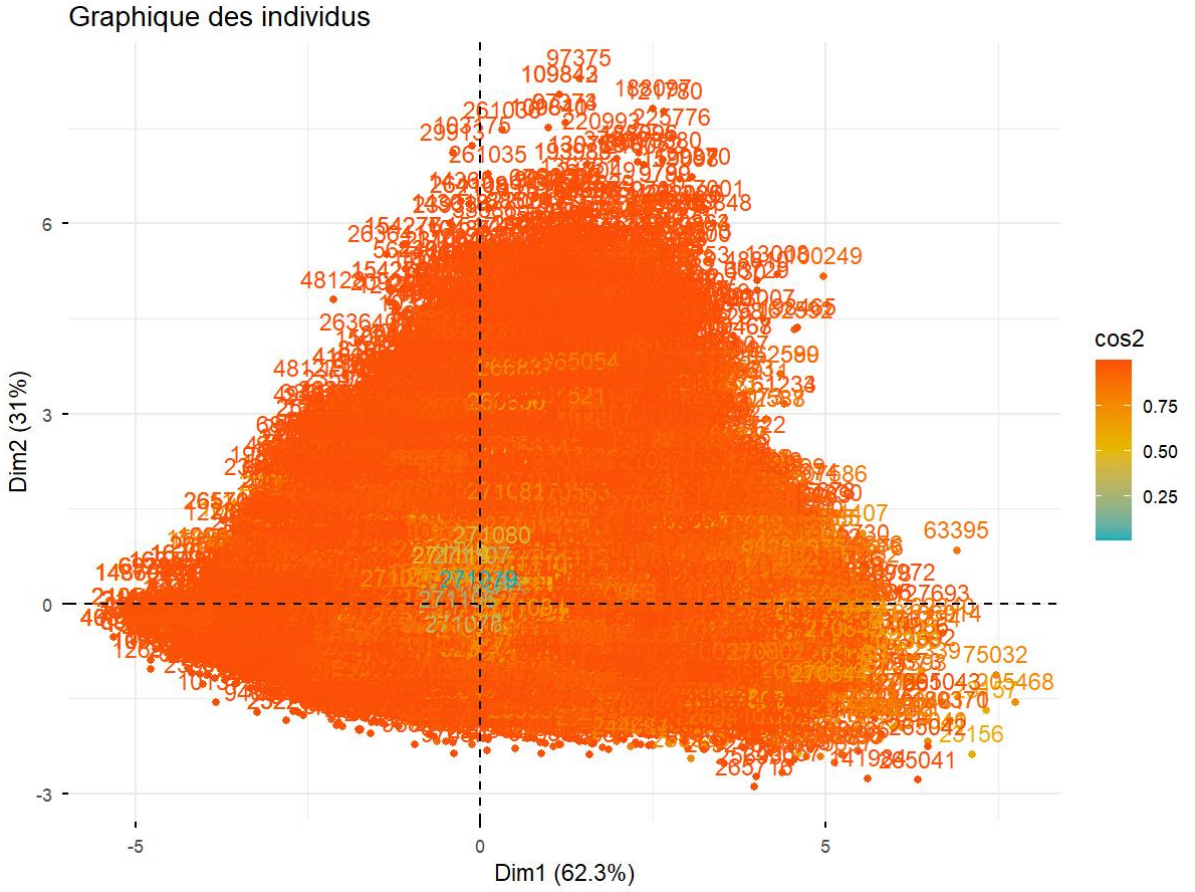


Figure 33 : Graphique des individus colorés par cos² (fviz_pca_ind)

Le nuage des 206 165 athlètes montre une concentration importante au centre du graphique, correspondant aux profils les plus courants (athlètes de taille et poids moyens, âge intermédiaire). Les individus colorés en rouge (cos² élevé) sont bien représentés par les deux axes retenus, tandis que les individus en bleu nécessiteraient plus de dimensions pour être parfaitement décrits.

On observe une légère dispersion horizontale (Dim.1) plus importante que la dispersion verticale (Dim.2), ce qui est cohérent avec le fait que la Dim.1 explique deux fois plus de variance que la Dim.2 (62% contre 31%).

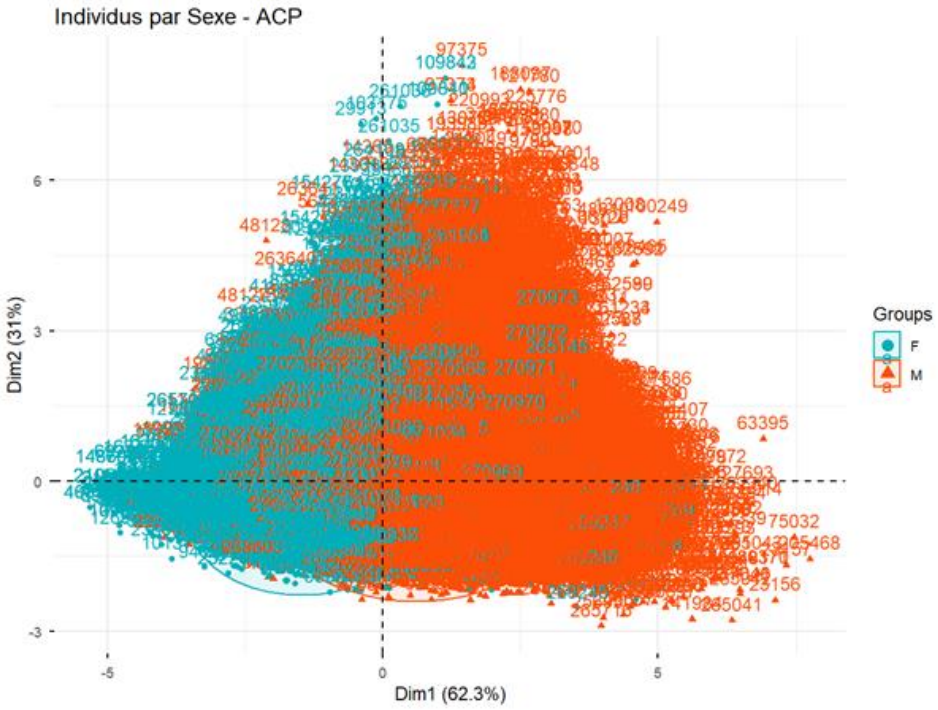


Figure 33 : Individus par Sexe — ACP (fviz_pca_ind par groupes)

Ce graphique reprend le même nuage d'individus mais en distinguant les femmes (points bleus, F) et les hommes (triangles orange, M). On observe clairement une **séparation entre les deux groupes sur la Dimension 1** :

- Les **femmes (bleu)** se concentrent majoritairement dans la partie **gauche** du graphique (valeurs négatives sur Dim.1), ce qui correspond à des athlètes de taille et poids plus faibles.
- Les **hommes (orange)** dominent la partie **droite** du graphique (valeurs positives sur Dim.1), correspondant à des athlètes plus grands et plus lourds.
- Sur la **Dimension 2** (axe vertical, liée à l'âge), les deux groupes se superposent, confirmant que les hommes et les femmes ont des profils d'âge équivalents.

Les ellipses de confiance ne se chevauchent que très légèrement, ce qui confirme que la **différence morphologique entre les sexes est statistiquement significative** et bien capturée par la Dimension 1.

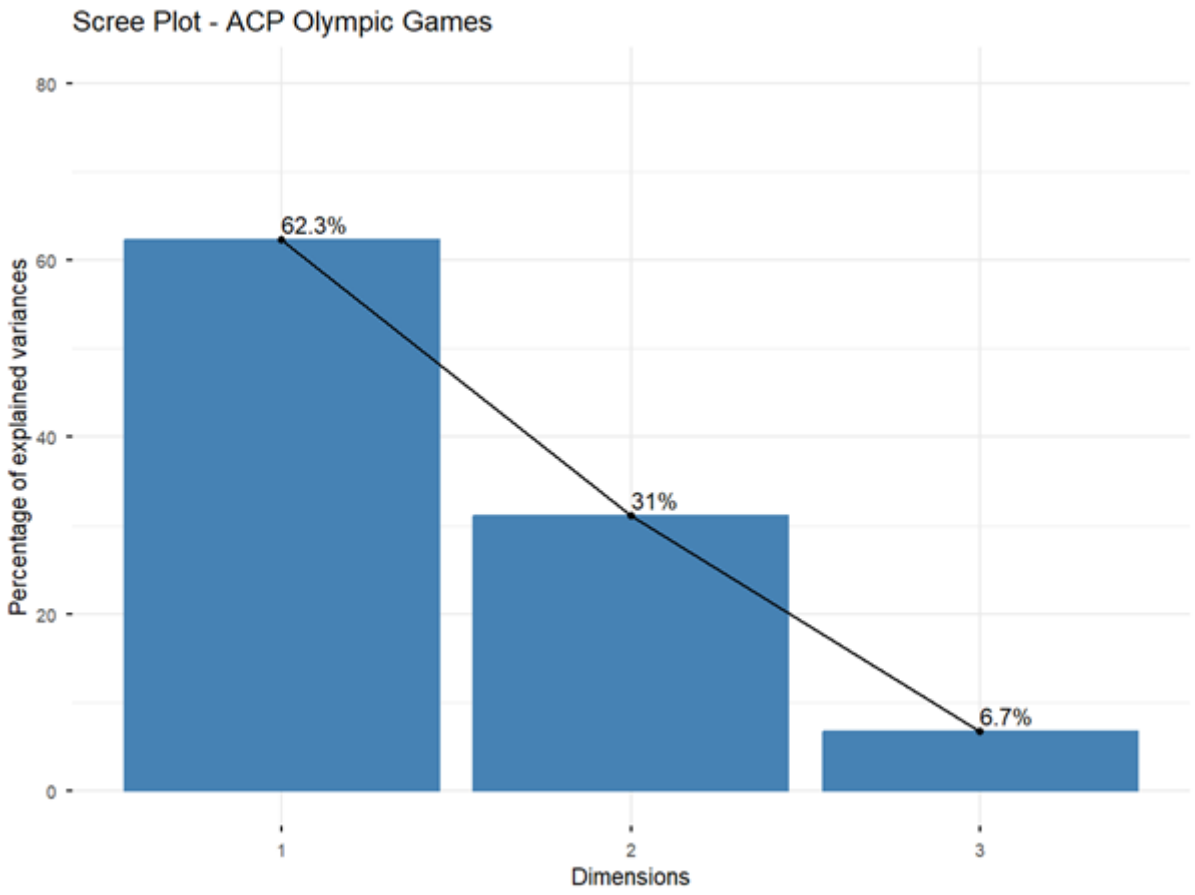


Figure 33 : Individus par Sexe — ACP (fviz_pca_ind par groupes)

Le Scree Plot (ou graphique des éboulis) représente la variance expliquée par chacune des trois dimensions :

- **Dimension 1 : 62.3%** — c'est la composante principale qui porte la majorité de l'information. Elle correspond à l'axe morphologique (taille et poids).
- **Dimension 2 : 31%** — apporte une information complémentaire significative, correspondant à l'axe d'âge.
- **Dimension 3 : 6.7%** — marginale et négligeable.

La courbe montre une chute nette entre la Dim.1 et la Dim.2, puis une stabilisation, confirmant que **retenir deux dimensions est largement suffisant** pour représenter 93.3% de l'information totale du dataset.

I.8 Biplot ACP

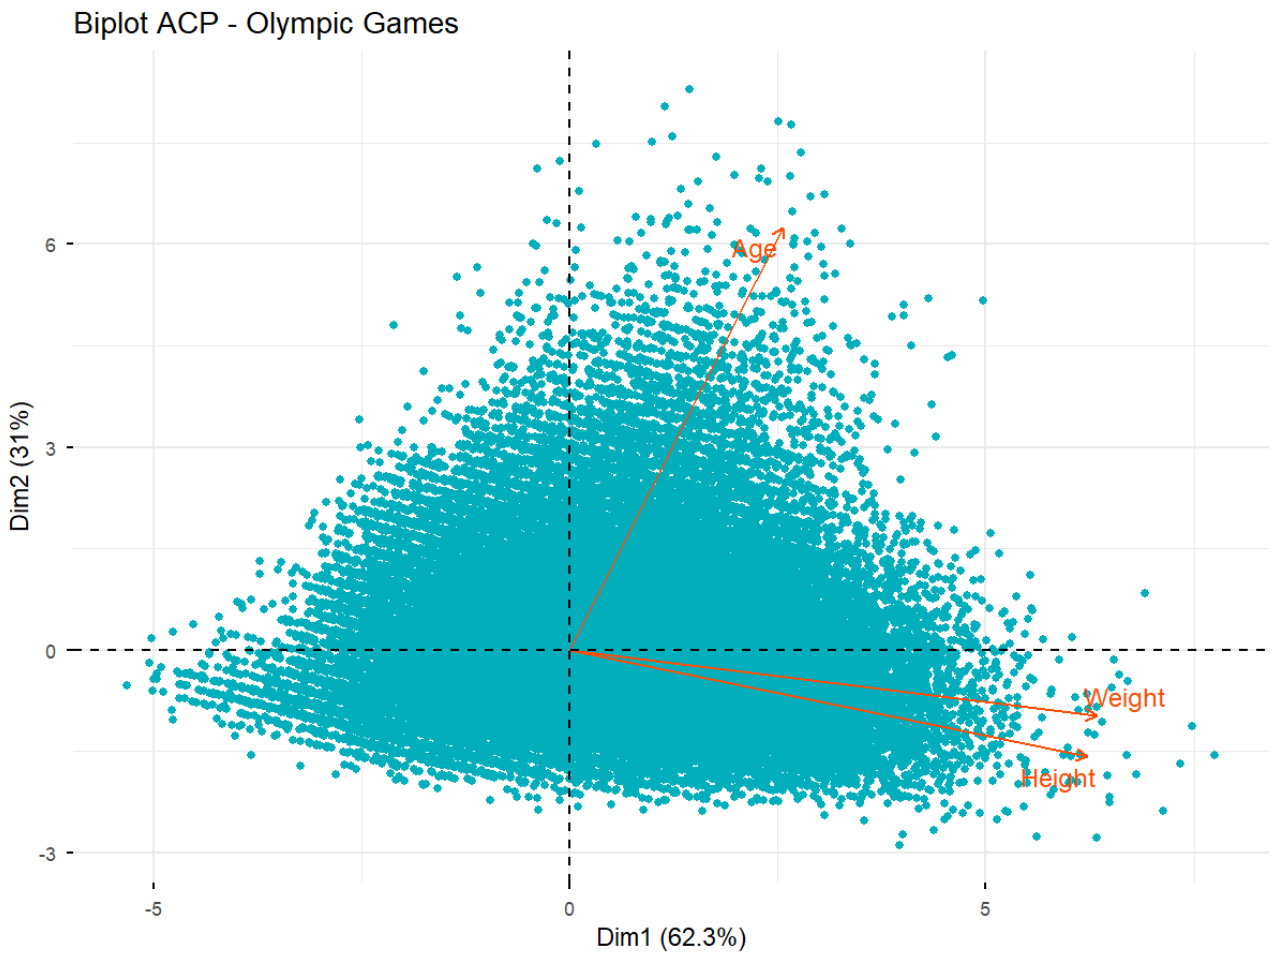


Figure 34 : Biplot ACP — Variables et Individus superposés

Le biplot combine les individus (points) et les variables (flèches) sur le même graphique. C'est la représentation la plus complète de l'ACP. On peut en déduire :

- **Athlètes à droite du graphique :** grande taille et poids élevé (contribution forte de Height et Weight sur Dim.1).
- **Athlètes à gauche du graphique :** plus petits et plus légers.
- **Athlètes en haut / en bas du graphique :** se distinguent principalement par leur âge (contribution forte de Age sur Dim.2).

Ce biplot confirme la structure bipolaire identifiée : un axe morphologique (Dim.1) représentant la corpulence, et un axe d'expérience (Dim.2) représentant l'âge.

II. Analyse Factorielle des Correspondances (AFC)

II.1 Présentation et Objectif

L'Analyse Factorielle des Correspondances (AFC) est une extension de l'ACP adaptée aux variables qualitatives. Elle permet de résumer et de visualiser l'information contenue dans un tableau de contingence formé par deux variables qualitatives, en représentant graphiquement leurs associations dans un espace à deux dimensions.

Dans notre étude, nous avons choisi de croiser les variables Sport et Medal. La question posée est : certains sports sont-ils plus associés à certains types de médailles (Bronze, Gold, Silver) qu'à d'autres ? Cette question est pertinente car certains sports ont des règles d'attribution des médailles spécifiques qui peuvent créer des déséquilibres.

II.2 Tableau de Contingence Sport × Medal

```
> t = table(data$Sport, data$Medal)
> t
```

	Bronze	Gold	Silver
Aeronautics	0	1	0
Alpine Skiing	141	143	144
Alpinism	0	25	0
Archery	98	135	120
Art Competitions	51	49	56
Athletics	1296	1339	1334
Badminton	60	54	54
Baseball	112	112	112
Basketball	356	365	359
Basque Pelota	0	2	0
Beach Volleyball	24	24	24
Biathlon	135	136	137
Bobsleigh	136	133	129
Boxing	441	252	251
Canoeing	389	388	388
Cricket	0	12	12
Croquet	2	4	2
Cross Country Skiing	263	256	257
Curling	49	50	53
Cycling	414	424	425
Diving	143	142	142
Equestrianism	319	324	322
Fencing	566	594	583
Figure Skating	127	131	128
Football	543	515	513
Freestyle Skiing	34	34	34
Golf	16	15	15
Gymnastics	719	791	746
Handball	353	349	358
Hockey	512	518	498
Ice Hockey	507	508	515
Jeu De Paume	1	1	1
Judo	274	137	136
Lacrosse	12	24	24
Luge	60	62	58
Military Ski Patrol	4	4	4
Modern Pentathlon	62	62	62

Figure 35 : Extrait du tableau de contingence Sport × Medal

Le tableau de contingence Sport × Medal a été construit avec la fonction table(). Il contient 66 sports en lignes et 3 types de médailles (Bronze, Gold, Silver) en colonnes, soit 198 cases au total. La fonction prop.table() permet d'obtenir les proportions relatives :

- **Athlétisme :** 1 296 Bronze, 1 339 Gold et 1 334 Silver — distribution parfaitement équilibrée.
- **Natation :** 956 Bronze, 1 099 Gold et 993 Silver.
- **Judo :** asymétrie notable avec 274 Bronze mais seulement 137 Gold et 136 Silver. Cette anomalie s'explique par les règles du Judo qui attribuent deux médailles de Bronze par épreuve (les deux perdants en demi-finale remportent chacun une médaille de Bronze).
- **Boxe :** même phénomène que le Judo avec 441 Bronze contre seulement 252 Gold et 251 Silver.

II.3 Test Khi-Deux

```
> chisq.test(t)

        Pearson's Chi-squared test

data:  t
X-squared = 325.88, df = 130, p-value < 2.2e-16
```

Figure 36 : Résultat du test Khi-deux — chisq.test(t)

Avant de réaliser l'AFC, il est obligatoire de vérifier l'existence d'une dépendance statistiquement significative entre les deux variables avec le test du khi-deux. Les hypothèses du test sont :

- **H0 :** les deux variables Sport et Medal sont indépendantes.
- **H1 :** il existe une association entre le sport pratiqué et le type de médaille.

Le résultat obtenu est : X-squared = 325.88 avec 130 degrés de liberté et p-value < 2.2e-16. La p-value est très largement inférieure au seuil de 0.05. On rejette donc l'hypothèse d'indépendance H0 et on conclut qu'il existe une relation statistiquement significative entre le sport pratiqué et le type de médaille obtenu. L'AFC est donc justifiée et pertinente.

II.4 Valeurs Propres de l'AFC

```
> valpropres
       eigenvalue variance.percent cumulative.variance.percent
Dim.1 0.006747688         82.37547                      82.37547
Dim.2 0.001443692         17.62453                     100.00000
```

Dimension	Valeur propre	Variance expliquée (%)	Variance cumulée (%)
Dim.1	0.006748	82.38%	82.38%
Dim.2	0.001444	17.62%	100.00%

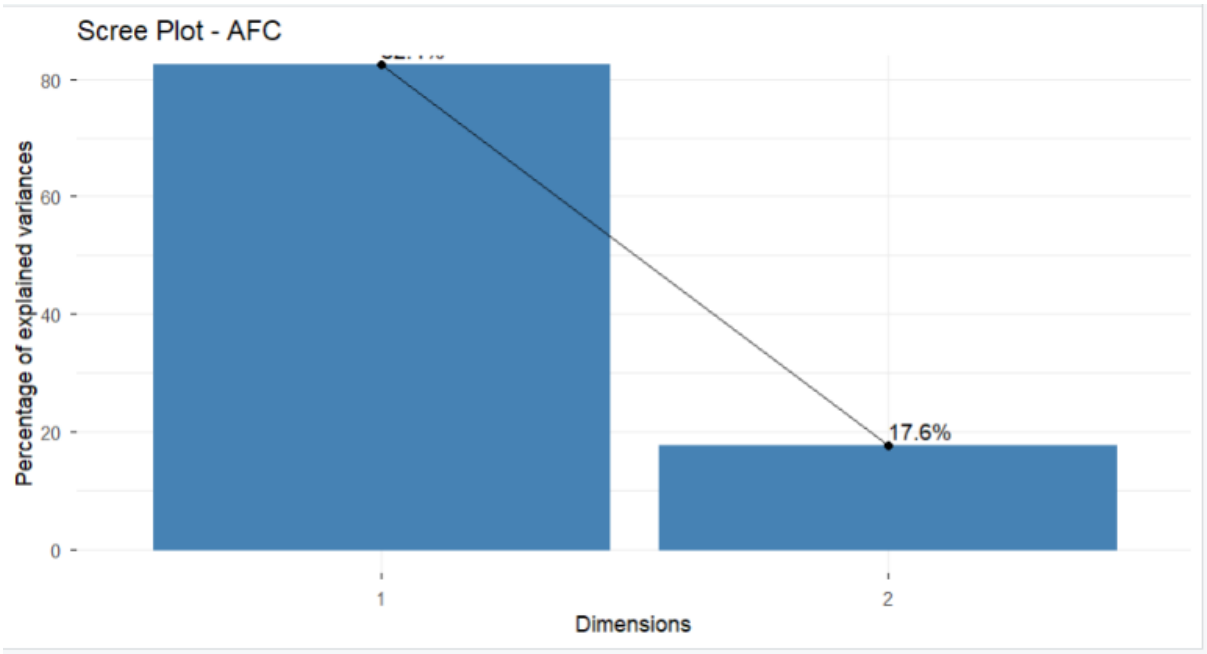


Figure 37 : Scree Plot — Valeurs propres de l'AFC

- **Dimension 1 (82.38%) :** explique la très grande majorité de la variance. C'est cette dimension qui capte l'essentiel de l'association entre Sport et Medal.
- **Dimension 2 (17.62%) :** explique les 17.62% restants.

Les deux axes expliquent ensemble 100% de la variance totale. Ce résultat est logique car la variable Medal ne comporte que 3 modalités, ce qui limite mécaniquement le nombre de dimensions possibles à 2 (nombre de modalités - 1 = 3 - 1 = 2).

II.5 Qualité de Représentation

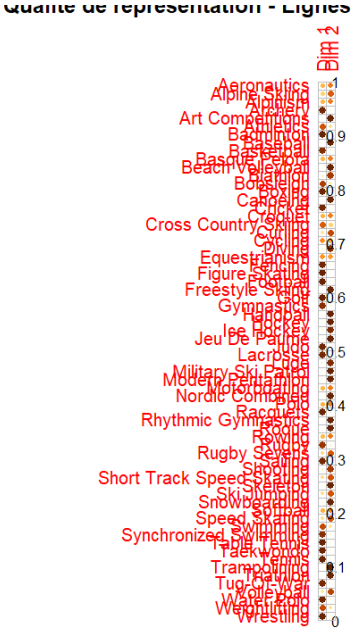


Figure 38 : Qualité de représentation des Sports — cos² des lignes

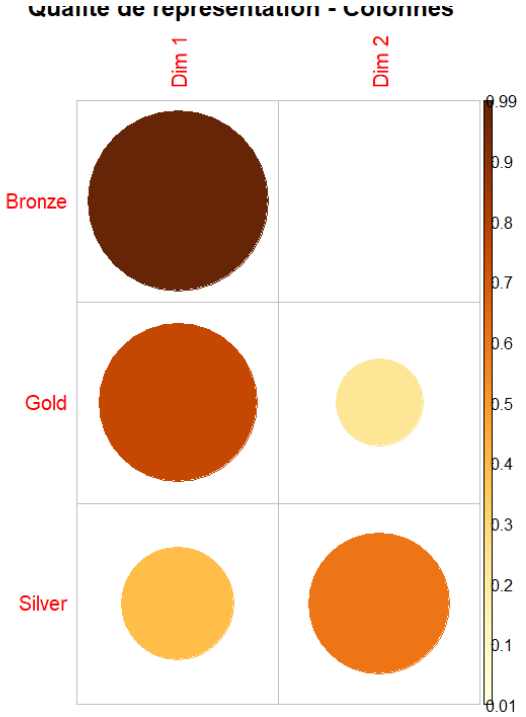


Figure 39 : Qualité de représentation des Médailles — cos² des colonnes

La qualité de représentation (cos²) mesure dans quelle mesure chaque élément (sport ou médaille) est bien représenté sur les axes retenus :

- **Sports à cos² élevé sur Dim.1 :** le Judo et la Boxe se distinguent nettement car leurs règles spécifiques créent un déséquilibre marqué dans la distribution des médailles (proportion de Bronze bien supérieure aux autres sports).
- **Les trois types de médailles :** Bronze, Gold et Silver sont bien représentés sur les deux dimensions, avec une meilleure représentation du Bronze sur la Dim.1.

Les sports présentant un cos² faible (proches du centre dans le biplot) sont ceux pour lesquels la distribution des médailles est équilibrée et donc peu différente de la distribution moyenne. Ces sports n'apportent pas d'information discriminante pour l'AFC.

II.6 Biplot AFC

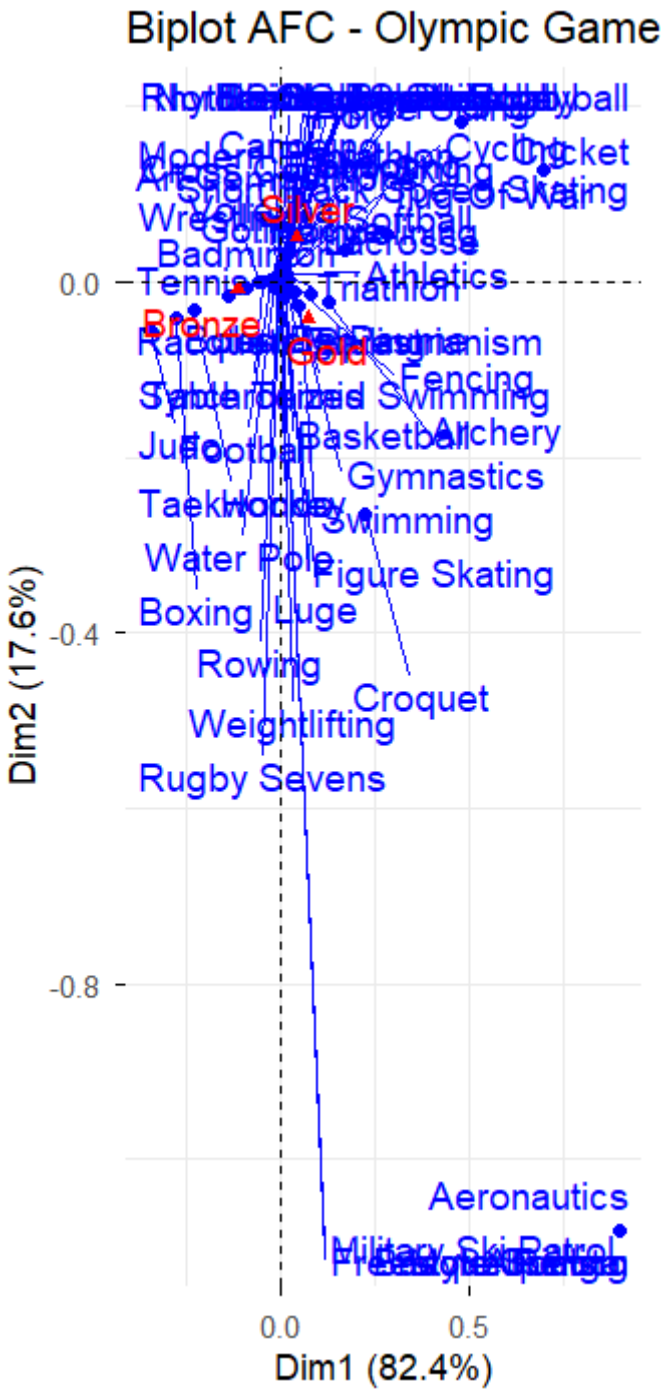


Figure 40 : Biplot AFC — Sports (points bleus) et Médailles (triangles rouges)

Le biplot AFC représente simultanément les sports (points bleus) et les médailles (triangles rouges) dans le même espace factoriel. La distance entre les points donne une mesure de la similitude ou de la dissimilitude entre les éléments. Interprétations :

- **Judo et Boxe éloignés du centre :** ces deux sports apparaissent clairement éloignés du centre et associés à la médaille Bronze, en raison de leurs règles spécifiques qui accordent deux médailles de Bronze par épreuve.
- **Majorité des sports au centre :** la plupart des disciplines se regroupent au centre du graphique, indiquant que pour ces sports, la distribution des trois types de médailles est relativement équilibrée et proche de la moyenne générale.

- **Gold et Silver proches l'une de l'autre :** les médailles d'or et d'argent sont proches dans l'espace factoriel, indiquant que les sports qui génèrent beaucoup d'or génèrent aussi beaucoup d'argent, ce qui est logique puisque les deux sont décernées par épreuve sans doublon.
- **Bronze plus isolé :** la médaille de Bronze est légèrement plus éloignée des deux autres, à cause des sports comme le Judo et la Boxe qui en génèrent davantage.

III. Conclusion de l'Analyse Multivariée

ACP — Résultats clés	AFC — Résultats clés
2 axes retiennent 93.33% de la variance	p-value < 2.2e-16 — dépendance confirmée
Dim.1 = axe morphologique (Height + Weight)	Dim.1 explique 82.4% de la variance AFC
Dim.2 = axe d'expérience (Age)	Judo et Boxe : surplus de Bronze (2/épreuve)
Height et Weight très corrélés (0.797)	Gold et Silver distribués de façon équilibrée

L'analyse multivariée appliquée au dataset Olympic Games nous a permis de dégager deux résultats majeurs.

D'une part, l'ACP révèle que les trois variables physiques des athlètes (Age, Height, Weight) peuvent être résumées en deux composantes principales expliquant 93.33% de la variance totale. La première composante représente la corpulence de l'athlète (taille et poids fortement liés, corrélation de 0.797), et la deuxième représente l'âge, variable totalement indépendante des caractéristiques morphologiques. Ce résultat est biologiquement cohérent et intuitivement attendu.

D'autre part, l'AFC confirme qu'il existe une association statistiquement très significative entre le sport pratiqué et le type de médaille obtenu (p-value < 2.2e-16). Cette association s'explique principalement par les règles spécifiques de certains sports comme le Judo et la Boxe, qui attribuent deux médailles de Bronze par épreuve, créant ainsi un déséquilibre notable dans la distribution des médailles par rapport aux autres disciplines.

Partie V — Conclusion Générale

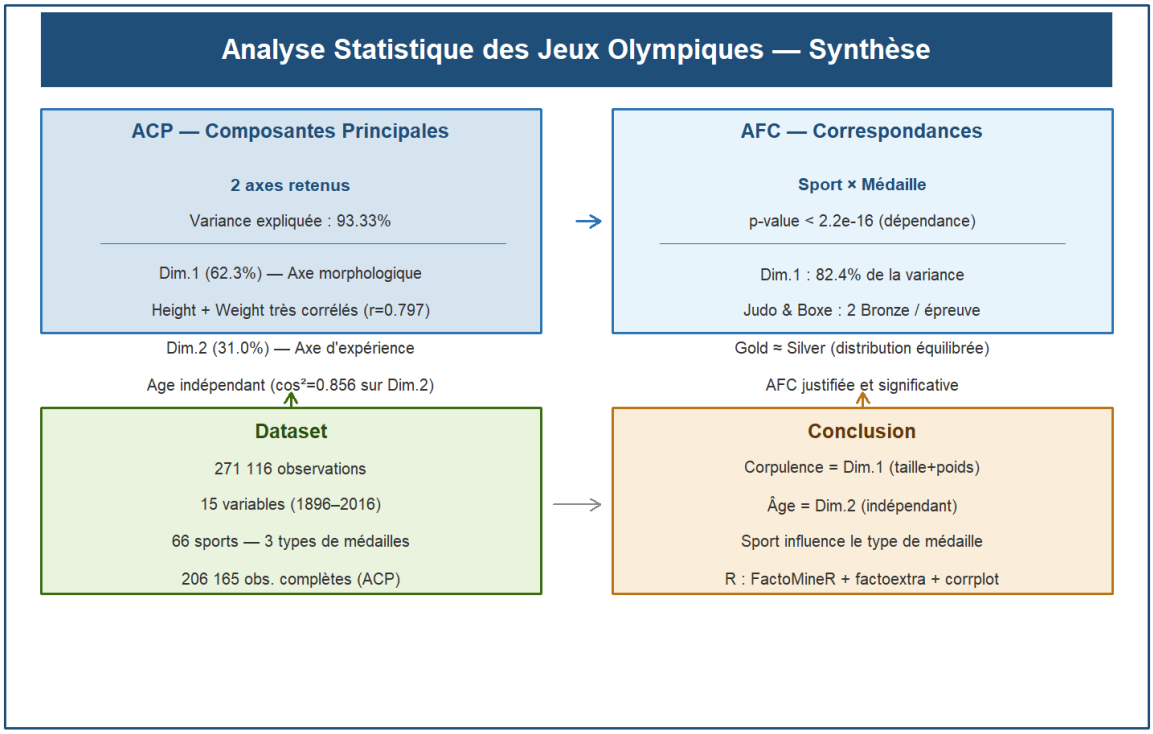


Figure 41 : Visualisation finale — récapitulatif

Ce projet d'analyse statistique du dataset Olympic Athletes Events (1896–2016) nous a permis d'explorer un jeu de données riche de 271 116 observations à travers trois niveaux d'analyse complémentaires, en utilisant le langage R et ses packages spécialisés (FactoMineR, factoextra, corrplot, MASS).

1. Bilan de l'Analyse Univariée

L'analyse univariée a révélé que l'athlète olympique typique est un homme d'environ 25 ans, mesurant 175 cm et pesant 70 kg. La participation olympique a été longtemps dominée par les hommes (72.52%) et par les Jeux d'été (82.07%). Le nombre de participants a considérablement augmenté au fil des décennies, passant de 380 athlètes en 1896 à près de 14 000 en 2016. La distribution des âges est asymétrique à droite, avec un pic autour de 22–25 ans, confirmant que le sport de haut niveau exige des capacités physiques qui atteignent leur sommet dans la vingtaine. Les variables de taille et de poids suivent des distributions symétriques et stables.

2. Bilan de l'Analyse Bivariée

L'analyse bivariée a mis en évidence une forte corrélation positive entre la taille et le poids des athlètes (r = 0.80), confirmée par le modèle de régression linéaire (Taille = 134 + 0.586 × Poids, R^2 = 0.634, p-value < 2.2e-16). Les intervalles de confiance à 95% sont très étroits grâce au grand nombre d'observations, attestant de la fiabilité des estimations. En revanche, l'âge s'avère statistiquement indépendant des caractéristiques morphologiques.

3. Bilan de l'Analyse Multivariée

L'analyse multivariée a apporté une vision globale et synthétique des données. L'ACP a permis de résumer les trois variables physiques en deux composantes principales expliquant 93.33% de la variance : un axe morphologique (corpulence) et un axe d'expérience (âge). L'AFC a confirmé l'existence d'une association statistiquement significative entre le sport pratiqué et le type de médaille obtenu, principalement due aux règles spécifiques du Judo et de la Boxe.

4. Apport du Projet

Ce projet illustre la puissance des outils statistiques de R pour analyser des données complexes et en extraire des informations claires et interprétables. Le dataset des Jeux Olympiques constitue un exemple idéal d'application des méthodes statistiques universitaires : sa richesse (variables quantitatives et qualitatives), sa taille (271 116 observations) et son thème universel permettent d'obtenir des résultats à la fois mathématiquement solides et facilement communicables.